

# **LAPORAN FINAL PROJECT**

## **METODE PERAMALAN**

APLIKASI MODEL GENERALIZED AUTOREGRESSIVE CONDITIONAL  
HETEROSKEDASTICITY (GARCH) DALAM ANALISIS VOLATILITAS NILAI  
TUKAR USD/IDR PERIODE JANUARI 2023-JUNI 2025

Dosen Pengampu: Dra. Ida Fithriani, M.SI.



**Disusun oleh Kelompok 7**

Bryant Farrel Titanius	2306212240
Fasya Nursyahda Kassuma	2306249672
Jaka Satria Gumlang	2306249735
Manda Liya Andini	2306262415

**DEPARTEMEN MATEMATIKA**  
**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM**  
**UNIVERSITAS INDONESIA**  
**2025**

**Tabel Kontribusi**

No	Nama	NPM	Kontribusi	Tingkat kontribusi
1	Bryant Farrel Titanius	2306212240	Terlibat aktif dalam diskusi kelompok, melakukan preprocessing dan pemodelan data, mengerjakan Bab II	100%
2	Fasya Nursyahda Kassuma	2306249672	Terlibat aktif dalam diskusi kelompok, dan mengerjakan Bab I yaitu Pendahuluan	100%
3	Jaka Satria Gumilang	2306249735	Terlibat aktif dalam diskusi kelompok, melakukan interpretasi & evaluasi model dan kesimpulan, mengerjakan Bab III & IV	100%
4	Manda Liya Andini	2306262415	Terlibat aktif dalam diskusi kelompok dan mengerjakan Bab III yaitu interpretasi dan analisis hasil	100%

## DAFTAR ISI

<b>BAB I.....</b>	<b>4</b>
<b>PENDAHULUAN.....</b>	<b>4</b>
1.1 Latar Belakang Masalah.....	4
1.2 Rumusan Masalah.....	4
1.3 Tujuan Penelitian.....	5
<b>BAB II.....</b>	<b>6</b>
<b>PENGOLAHAN DATA.....</b>	<b>6</b>
2.1 Eksplorasi dan Visualisasi Data.....	6
2.1.1 Deskripsi Data.....	6
2.1.2 Eksplorasi Data.....	7
2.2 Analisis dan Pemodelan.....	11
2.2.1 Pemodelan.....	11
2.2.2 Analisis Residual.....	23
2.2.3 Peramalan.....	28
<b>BAB III.....</b>	<b>33</b>
<b>INTERPRETASI.....</b>	<b>33</b>
3.1 Interpretasi Model ARMA(2,2)-GARCH(1,1).....	33
3.1.1 Interpretasi Komponen ARMA(2,2).....	33
3.1.2 Interpretasi Komponen GARCH(1,1).....	34
3.2 Interpretasi Validasi Model.....	34
3.3 Analisis Volatilitas Nilai Tukar USD/IDR.....	36
3.4 Evaluasi dan Interpretasi Hasil Peramalan.....	37
3.5 Keterbatasan Model.....	39
<b>BAB IV.....</b>	<b>41</b>
<b>KESIMPULAN.....</b>	<b>41</b>
4.1 Kesimpulan.....	41
4.2 Saran.....	41
<b>LAMPIRAN.....</b>	<b>42</b>

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang Masalah

Nilai tukar mata uang merupakan indikator ekonomi yang sangat sensitif dan memainkan peran penting dalam stabilitas ekonomi suatu negara. Pergerakan nilai tukar yang fluktuatif dapat memengaruhi berbagai sektor, seperti perdagangan internasional, inflasi, suku bunga, investasi, dan utang luar negeri. Salah satu mata uang yang paling diperhatikan dalam konteks perekonomian Indonesia adalah nilai tukar Rupiah terhadap Dolar Amerika Serikat (USD), mengingat perannya sebagai mata uang utama dalam transaksi internasional.

Dalam praktiknya, nilai tukar sering kali menunjukkan pola pergerakan yang tidak hanya mengikuti tren atau siklus tertentu, tetapi juga mengalami volatilitas, yaitu perubahan besar secara tiba-tiba dalam periode waktu singkat. Fenomena ini menjadi perhatian khusus bagi para pengambil kebijakan, pelaku pasar, dan akademisi karena ketidakpastian yang tinggi dapat meningkatkan risiko dalam pengambilan keputusan ekonomi.

Secara statistik, volatilitas ini seringkali tidak dapat dijelaskan secara efektif oleh model linier konvensional seperti ARMA atau ARIMA karena model-model tersebut mengasumsikan varians residual yang konstan (*homoskedastisitas*). Padahal, dalam kenyataannya, varians dari error atau residual seringkali berubah-ubah dari waktu ke waktu suatu kondisi yang dikenal sebagai heteroskedastisitas bersyarat (*conditional heteroskedasticity*). Oleh karena itu, dibutuhkan pendekatan pemodelan yang mampu menangkap dinamika varians tersebut secara lebih akurat.

Model GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*) merupakan salah satu model statistik yang dikembangkan untuk menangani masalah tersebut. Model ini memungkinkan estimasi volatilitas dengan mempertimbangkan ketergantungan varians saat ini terhadap varians dan galat (residual) di masa lalu. Model GARCH(1,1), sebagai bentuk paling sederhana namun sangat populer, banyak digunakan untuk menganalisis volatilitas data keuangan termasuk nilai tukar.

### 1.2 Rumusan Masalah

Dalam penelitian ini, fokus utama diarahkan pada analisis volatilitas data nilai tukar Rupiah terhadap Dolar AS menggunakan pendekatan model GARCH(1,1). Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah yang ingin dikaji secara mendalam dalam penelitian ini dapat dirinci sebagai berikut:

1. **Bagaimana karakteristik statistik dari data runtun waktu nilai tukar Rupiah terhadap Dolar AS?**

Hal ini mencakup identifikasi pola umum, tren, stasioneritas, serta distribusi data historis nilai tukar yang digunakan.

**2. Apakah terdapat indikasi volatilitas yang bersifat heteroskedastik dalam data nilai tukar tersebut?**

Tujuannya untuk melihat apakah varians residual dari data menunjukkan pola yang berubah-ubah (time-varying volatility), yang tidak dapat dijelaskan oleh model linear biasa.

**3. Bagaimana proses estimasi dan hasil penerapan model GARCH(1,1) terhadap data nilai tukar tersebut?**

Ini termasuk penentuan parameter model, pengujian asumsi, serta interpretasi hasil model yang diestimasi.

**4. Apakah model GARCH(1,1) mampu memberikan estimasi volatilitas yang representatif terhadap dinamika nilai tukar Rupiah terhadap Dolar AS?**

Pertanyaan ini menilai kemampuan model dalam menangkap perubahan varians dari waktu ke waktu dan implikasi penggunaannya.

### **1.3 Tujuan Penelitian**

Tujuan dari penelitian ini secara umum adalah untuk menganalisis dan memodelkan volatilitas nilai tukar Rupiah terhadap Dolar AS dengan menggunakan model GARCH(1,1). Secara khusus, penelitian ini bertujuan untuk:

1. Menganalisis karakteristik statistik dari data runtun waktu nilai tukar Rupiah terhadap Dolar AS, termasuk sifat stasioneritas dan pola distribusi data.
2. Mengidentifikasi adanya gejala heteroskedastisitas bersyarat pada data nilai tukar.
3. Membangun dan mengestimasi model GARCH(1,1) untuk menggambarkan dinamika volatilitas nilai tukar.
4. Mengevaluasi performa model dalam menjelaskan variasi varians dan menilai seberapa baik model tersebut dapat digunakan untuk analisis volatilitas ekonomi.
5. Memberikan wawasan atau implikasi dari hasil analisis kepada pihak-pihak yang berkepentingan, seperti pengambil kebijakan, pelaku pasar, dan akademisi, dalam memahami risiko yang berkaitan dengan fluktuasi nilai tukar.

## **BAB II**

### **PENGOLAHAN DATA**

#### **2.1 Eksplorasi dan Visualisasi Data**

Sebelum melakukan analisis, perlu dilakukan elaborasi pada data untuk mendapatkan informasi-informasi yang diperlukan. Meskipun data yang digunakan berupa runtun waktu, bisa saja terdapat masalah pada data, misalnya seperti data yang hilang di suatu waktu tertentu atau penulisan yang kurang tepat. Untuk melakukan elaborasi data ini, pertama data akan dijelaskan dan dideskripsikan secara jelas. Kemudian, dilakukan eksplorasi pada data untuk mencari masalah-masalah yang bisa saja terdapat pada data.

##### **2.1.1 Deskripsi Data**

Data yang digunakan adalah data historis nilai tukar mata uang dolar Amerika (USD) dengan mata uang Rupiah (IDR). Data diambil dan diunduh secara manual dari situs <https://id.investing.com/currencies/usd-idr-historical-data>, dimana datanya berupa harian dan diambil mulai dari tanggal 1 Januari 2023 (01-01-2023) sampai dengan 1 Juni 2025 (01-06-2025). Pengambilan tanggal ini dilakukan untuk memodelkan runtun waktu harian dari awal tahun 2023 sampai pertengahan tahun 2025.

Data yang diperoleh berukuran 621x7, yang berarti terdapat 621 baris yang berisikan tanggal dan nilai-nilai tukar di periode perdagangan dan 7 kolom sebagai berikut:

- Kolom **Tanggal** berisikan data mengenai tanggal dicatatnya nilai tukar. Tanggal ini penting sebagai dasar untuk memberikan indeks waktu pada runtun yang nantinya akan diperoleh.
- Kolom **Terakhir** berisikan data mengenai nilai tukar USD/IDR di akhir periode perdagangan/transaksi pada tanggal tersebut. Dalam bahasa Inggris, data ini seringkali disebut “closing price”, yang juga lebih umum untuk digunakan dalam melakukan pemodelan runtun waktu finansial.
- Kolom **Pembukaan** atau “opening price” berisikan data mengenai nilai tukar USD/IDR di awal periode perdagangan pada tanggal tersebut.
- Kolom **Tertinggi** berisikan data mengenai nilai tukar USD/IDR tertinggi selama periode perdagangan pada tanggal tersebut.
- Kolom **Terendah** berisikan data mengenai nilai tukar USD/IDR terendah selama periode perdagangan pada tanggal tersebut.
- Kolom **Vol.** berisikan data mengenai total banyaknya pertukaran mata uang yang terjadi selama periode tersebut.
- Kolom **Perubahan%** berisikan data mengenai perubahan *closing price* suatu tanggal dengan tanggal sebelumnya dalam persentase. Jika terjadi kenaikan pada nilai tukar, maka kenaikan tersebut tidak akan ditandai, tetapi jika terjadi penurunan, maka penurunan akan ditandai dengan tanda negatif.

Kemudian, banyaknya baris yaitu sebanyak 621 juga masuk akal, karena kurang lebih terdapat  $52 \times 2 = 104$  minggu dari awal 2023 sampai akhir 2024 ditambah dengan sekitar 20 minggu dari awal 2025 sampai 1 Juni 2025, yang berarti kira-kira terdapat  $124 \times 5 = 620$  hari

yang bukan hari Sabtu atau Minggu dari tanggal 1 Januari 2025 sampai tanggal 1 Juni 2025. Hasil perkiraan ini cukup mendekati jumlah baris pada data yang kami miliki.

### 2.1.2 Eksplorasi Data

Setelah data telah dideskripsikan dengan jelas, akan dilakukan preprocessing data untuk merapikan dan membersihkan data. Dari preprocessing data ini, akan diperoleh data runtun waktu yang kemudian dapat digunakan untuk melakukan pemodelan.

Pertama, data diurutkan terlebih dahulu berdasarkan kolom **Tanggal**. Hal ini dilakukan untuk memudahkan pendefinisian runtun waktu. Setelah data diurutkan berdasarkan tanggal, dibuat kolom baru bernama **Time\_Index** yang berisikan indeks data yang sudah sesuai dengan urutan tanggal. Kolom baru ini akan merepresentasikan waktu nilai tukar pada runtun waktu.

Kemudian, data pada kolom **Terakhir**, **Pembukaan**, **Tertinggi**, dan **Terendah** juga bermasalah, karena satuan yang terdapat pada data belum tepat dan tidak sesuai dengan nilai tukar sebenarnya. Contohnya, di baris pertama pada kolom **Terakhir**, entrinya bernilai 15.5700, padahal seharusnya entri tersebut bernilai 15570.0. Hal yang sama terjadi di ketiga kolom lainnya, sehingga setiap entri pada keempat kolom tersebut dikalikan dengan 1000 untuk memperbaiki satuan.

Selanjutnya, perhatikan juga bahwa kolom **Vol.** seluruhnya bernilai kosong atau NA. Hal ini memang seringkali terjadi pada data finansial, karena volume biasanya kurang relevan dan tidak penting untuk dicatat. Bahkan jika kolom **Vol.** ini seluruhnya diketahui dan nilainya tidak kosong, data ini tidak akan digunakan karena memang pemodelan yang akan dilakukan adalah runtun waktu dari *closing price* nya dan bukan volumenya. Oleh karena itu, kolom **Vol.** ini akan dihapuskan dari data keseluruhan.

Setelah data diurutkan berdasarkan waktu dan satuannya dibenarkan, dapat dibuat plot untuk masing-masing kolom terhadap waktu. Berikut ini adalah plot *closing price* atau nilai tukar terakhir terhadap waktu.



**Gambar 2.1.** Plot *closing price* terhadap waktu

Perhatikan bahwa runtun waktu ini cenderung naik secara pelan-pelan dalam jangka waktu yang cukup panjang. Terjadi juga beberapa kali kenaikan dan penurunan yang cepat di beberapa waktu tertentu, seperti contoh kenaikan yang cepat yaitu di sekitar waktu 30, 190, 300, atau 440, dan penurunan yang cepat di sekitar waktu 50, 200, 400, dan 600. Hal ini tentu memberikan petunjuk bahwa model yang tepat untuk memodelkan runtun waktu nilai tukar ini adalah model ARIMA pada mean dan GARCH untuk volatilitas. Model ARIMA pada mean diperkirakan bisa ada karena adanya kecenderungan nilai tukar untuk naik secara pelan-pelan dalam jangka waktu yang cukup panjang, dan model GARCH untuk volatilitas diperkirakan bisa ada karena adanya kecenderungan nilai tukar untuk naik/turun dengan cepat setelah diikuti dengan kenaikan atau penurunan yang cepat pula.

Selain membuat plot pada *closing price*, bisa juga dibuat plot untuk *opening price*, *highest price*, dan juga *lowest price* pada setiap periode perdagangan. Berikut adalah plot untuk *opening price* atau nilai tukar pembukaan di awal periode perdagangan terhadap waktu:



**Gambar 2.2.** Plot *opening price* terhadap waktu

Ternyata, plot *opening price* ini tidak berbeda terlalu jauh dengan plot *closing price*. Meskipun demikian, runtun waktu *opening price* tidak akan digunakan untuk pemodelan karena nilai tukar pembukaan akan langsung berubah saat periode perdagangan dimulai. Sedangkan, nilai tukar terakhir tidak akan berubah lagi sampai periode perdagangan di keesokan hari dimulai. Selanjutnya, plot untuk *highest price* dan juga *lowest price* terdapat di bawah ini.



**Gambar 2.3.** Plot *highest price* terhadap waktu

Plot Runtun Waktu Lowest Price

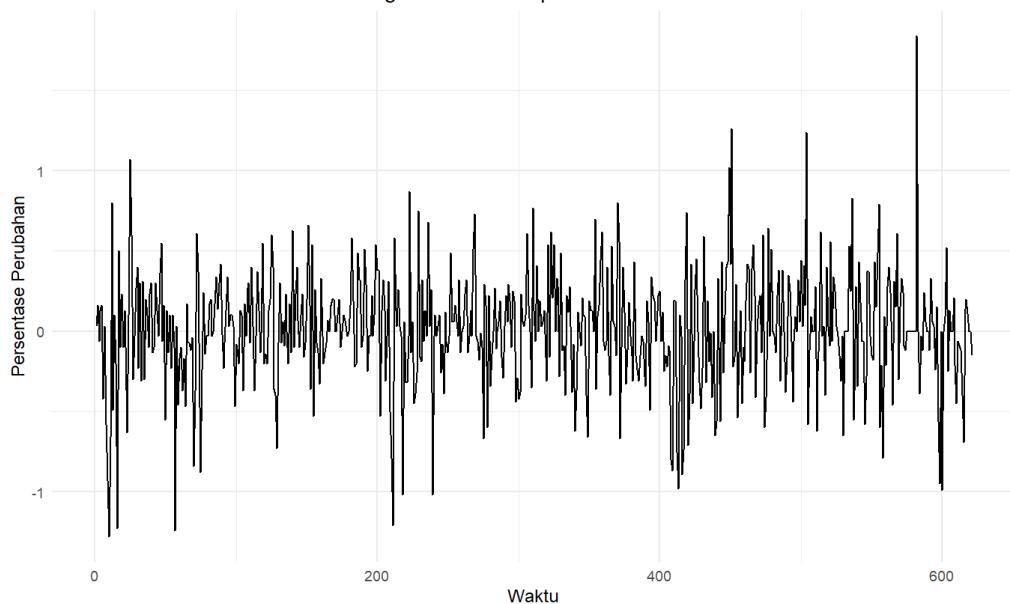


**Gambar 2.4.** Plot *lowest price* terhadap waktu

Ternyata, kedua plot di atas juga tidak berbeda terlalu jauh dengan plot *closing price* terhadap waktu. Jadi, tidak perlu dilakukan pemodelan runtun waktu yang berbeda untuk seluruh bentuk ukuran nilai tukar, dan hanya akan digunakan *closing price*.

Terakhir, hal menarik selanjutnya yang dapat dilihat dalam eksplorasi data adalah plot persentase perubahan *closing price* terhadap waktu. Berikut adalah plot perubahan tersebut.

Plot Persentase Perubahan Closing Price Terhadap Waktu



**Gambar 2.5.** Plot persentase perubahan *closing price* terhadap waktu

Pada plot tersebut, dapat dilihat bahwa persentase perubahannya menyerupai *white noise* yang berpusat pada nol (memiliki mean nol). Kemudian, perhatikan juga bahwa tidak ada persentase perubahan yang terlalu tinggi. Persentase perubahan yang tertinggi yaitu hampir mencapai 2%, tetapi tidak ada perubahan lainnya yang lebih dari itu. Hal ini berarti belum ditemukan outlier pada persentase perubahan, yang berarti belum terdapat outlier yang mencolok pada data nilai tukar yang dimiliki, meskipun terdapat sebanyak 621 observasi. Ini merupakan hal yang baik, karena dapat menghindari perlunya penghapusan data outlier yang dapat menghilangkan informasi berharga.

## 2.2 Analisis dan Pemodelan

Setelah dilakukan eksplorasi dan visualisasi data, runtun waktu akan dianalisis dan dimodelkan. Karena data yang digunakan adalah data finansial, maka model yang paling tepat untuk mendeskripsikan runtun waktu ini adalah model ARIMA + GARCH. Hal ini karena model ARIMA mampu menangkap tren yang terdapat pada data, dan model GARCH mampu menangkap volatilitas yang terdapat pada data, dimana volatilitas ini berarti variansi besar akan diikuti pula oleh variansi yang besar, dan sebaliknya. Sifat volatilitas ini mampu dimodelkan dengan GARCH menggunakan variansi bersyarat. Bersama dengan ARIMA, kedua model ini akan digunakan untuk memodelkan runtun waktu nilai tukar USD/IDR.

### 2.2.1 Pemodelan

Ingat kembali model untuk volatilitas atau variansi bersyarat dari GARCH(p,q), yaitu  $Var(r_t | \mathcal{F}_{t-1}) = \sigma_{t|t-1}^2 = \omega + \alpha_1 r_{t-1}^2 + \dots + \alpha_q r_{t-q}^2 + \beta_1 \sigma_{t-1|t-2}^2 + \dots + \beta_p \sigma_{t-p|t-p-1}^2$  dengan model untuk return  $r_t$  yaitu

$$r_t = \varepsilon_t \sigma_{t|t-1}$$

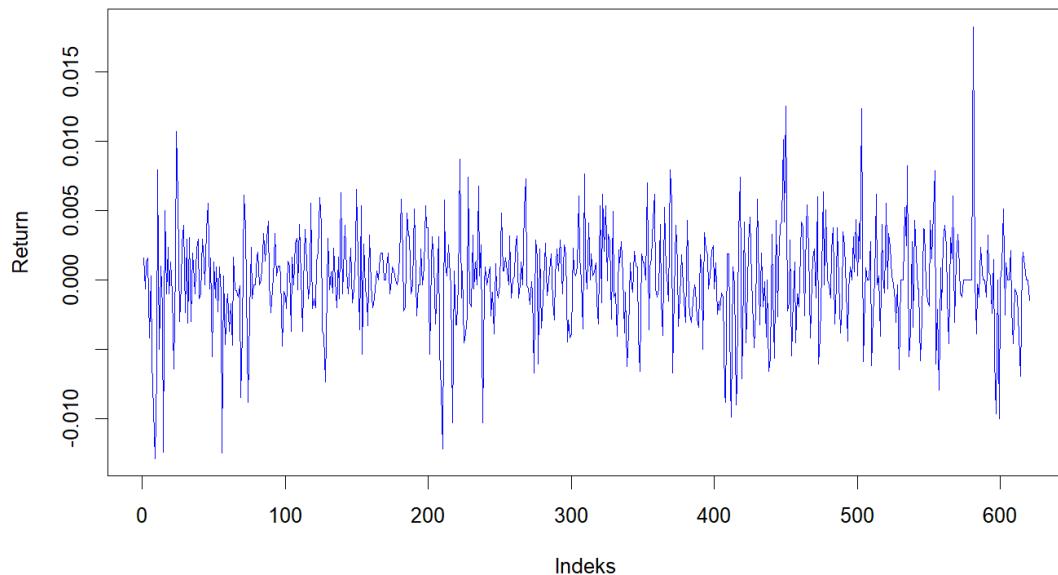
dimana  $\varepsilon_t$  diasumsikan berdistribusi identik dan independen dengan mean nol dan variansi 1,

$\sigma_{t|t-1} = \sqrt{\sigma_{t|t-1}^2}$ , dan  $r_t$  adalah return yang didefinisikan sebagai

$$r_t = \ln(p_t) - \ln(p_{t-1})$$

dimana  $\{p_t\}$  adalah runtun waktu awal. Dalam konteks pemodelan yang akan dilakukan,  $\{p_t\}$  akan merujuk kepada runtun waktu *closing prices* dengan nilai-nilai  $t$  yang diketahui dimulai dari 1 sampai 621. Pemodelan volatilitas atau variansi bersyarat menggunakan GARCH(p,q) ini juga didukung oleh hasil visualisasi plot *closing price* pada subbab sebelumnya, dan juga plot return sebagai berikut, dimana return yang besar akan cenderung diikuti dengan return yang besar pula.

**Plot Return Terhadap Waktu**



**Gambar 2.6.** Plot return terhadap waktu untuk *closing prices*

Kemudian, ingat kembali bahwa plot *closing prices* memberikan informasi bahwa terdapat tren yang cenderung naik pada nilai tukar. Hal ini berarti diperlukan model untuk menjelaskan tren kenaikan ini, karena tren kenaikan tidak dapat dijelaskan hanya menggunakan GARCH(p,q) yang hanya menangkap volatilitas. Oleh karena itu, diperlukan model ARIMA(p,d,q) untuk menjelaskan tren ini. Ingat kembali model ARIMA(p,d,q) untuk proses return  $\{r_t\}$  dengan notasi backshift akan berbentuk

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)(1 - B)^d r_t = \theta_0 + (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) e_t,$$

dimana  $e_t$  diasumsikan adalah white noise dengan mean 0 dan variansi  $\sigma_e^2$ , dan  $\theta_0$  adalah parameter mean. Jika dituliskan kembali tanpa notasi backshift, modelnya menjadi

$$\nabla^d r_t = \phi_1 \nabla^d r_{t-1} + \dots + \phi_p \nabla^d r_{t-p} + \theta_0 + e_t - \theta_1 e_{t-1} - \dots - \theta_q e_{t-q}$$

dimana  $\nabla^d r_t = \nabla^{d-1} r_t - \nabla^{d-1} r_{t-1}$  merupakan notasi differencing orde-d.

Untuk menggabungkan model ARIMA(p,d,q) dengan model GARCH(p,q), maka perlu diasumsikan bahwa  $e_t$  pada ARIMA(p,d,q) tersebut memiliki model GARCH(p,q), dimana

$$e_t = \varepsilon_t \sigma_{t|t-1}$$

dengan

$$\sigma_{t|t-1}^2 = \omega + \alpha_1 e_{t-1}^2 + \dots + \alpha_p e_{t-p}^2 + \beta_1 \sigma_{t-1|t-2}^2 + \dots + \beta_p \sigma_{t-p|t-p-1}^2$$

dan  $\varepsilon_t$  berdistribusi identik dengan mean nol dan variansi 1. Dengan menggunakan model gabungan ini, term error  $e_t$  pada runtun waktu ARIMA yang biasanya diasumsikan memiliki

variansi  $\sigma_e^2$  berubah menjadi memiliki variansi bersyarat  $\sigma_{t|t-1}^2$ . Atau, dengan kata lain, gabungan ARIMA(p,d,q) dengan GARCH(p,q) memiliki bentuk model

$$\nabla^d r_t = \phi_1 \nabla^d r_{t-1} + \dots + \phi_p \nabla^d r_{t-p} + \theta_0 + e_t - \theta_1 e_{t-1} - \dots - \theta_q e_{t-q}$$

dengan  $e_t \sim IID(0, \sigma_{t|t-1}^2)$ .

Sebelum melakukan pemodelan, perlu diuji terlebih dahulu apakah runtun waktu return yang dimiliki memang stasioner atau tidak. Untuk melakukan pengujian ini, dilakukan uji Augmented Dickey-Fuller (ADF) untuk menguji stasioneritas. Menggunakan R, diperoleh output uji ADF sebagai berikut.

```
Augmented Dickey-Fuller Test

data: returns
Dickey-Fuller = -7.7318, Lag order = 8, p-value = 0.01
alternative hypothesis: stationary
```

**Gambar 2.7.** Uji ADF pada runtun waktu return

Perhatikan bahwa p-value nya 0.01 yang lebih kecil dari 0.05. Hal ini berarti hipotesis null yang menyatakan adanya unit root ditolak. Artinya tidak ada indikasi terdapat unit root, sehingga dapat disimpulkan bahwa return mengikuti model yang stasioner. Ini berarti tidak diperlukan model ARIMA(p,d,q) untuk memodelkan runtun waktu, cukup ARMA(p,q) saja.

Setelah ditentukan model yang ingin dispesifikasikan untuk return, yaitu model ARMA(p,q) + GARCH(p,q), pertama akan dispesifikasikan parameter-parameter p dan q pada ARMA untuk memodelkan tren. Menggunakan fungsi auto.arima pada R yang dapat memilih model ARIMA terbaik berdasarkan AIC, AICc (corrected AIC), dan BIC, diperoleh output sebagai berikut.

```
Series: returns
ARIMA(2,0,2) with zero mean

Coefficients:
      ar1      ar2      ma1      ma2
     -0.8415  -0.8838  0.9097  0.9440
  s.e.  0.0508   0.0467  0.0350  0.0362

sigma^2 = 1.26e-05: log likelihood = 2619.33
AIC=-5228.66  AICc=-5228.57  BIC=-5206.52

Training set error measures:
          ME        RMSE        MAE        MPE        MAPE        MASE        ACF1
Training set 6.72372e-05 0.003538687 0.002595979  NaN    Inf  0.7059881  0.02252367
```

**Gambar 2.8.** Spesifikasi model terbaik berdasarkan AIC, AICc, dan BIC.

Jadi, diperoleh model terbaik untuk tren stokastik dari return  $\{r_t\}$  yaitu ARMA(2,2), dengan mean nol. Dengan kata lain, model untuk return sejauh ini dapat dituliskan sebagai

$$r_t = \hat{\phi}_1 r_{t-1} + \hat{\phi}_2 r_{t-2} + e_t - \hat{\theta}_1 e_{t-1} - \hat{\theta}_2 e_{t-2},$$

dimana  $\hat{\phi}_1, \hat{\phi}_2, \hat{\theta}_1, \hat{\theta}_2$  adalah estimasi untuk parameter-parameter ARMA(2,2). Kemudian, perhatikan juga bahwa standar error dari setiap estimasi cukup kecil dibandingkan dengan hasil estimasinya. Hal ini berarti setiap parameter yang diestimasi signifikan, yang lebih lanjut meneguhkan kembali spesifikasi model ARMA(2,2) Meskipun demikian, hati-hati karena belum dapat dituliskan model matematis

$$r_t = -0.8415r_{t-1} - 0.8838r_{t-2} + e_t + 0.9097e_{t-1} + 0.9440e_{t-2}$$

sebagai model untuk return, karena volatilitas atau variansi bersyarat  $e_t$  belum diestimasi. Untuk ini, akan diasumsikan model GARCH(p,q) pada  $e_t$ , yang akan dispesifikasikan selanjutnya.

Biasanya, runtun waktu finansial tidak memerlukan model GARCH yang terlalu rumit. Model GARCH(1,1) umumnya sudah cukup untuk menangkap volatilitas pada data. Oleh karena itu, pertama akan dicoba untuk menggunakan model GARCH(1,1) ditambah dengan model ARMA(2,2) tanpa mean pada runtun waktu. Dengan asumsi bahwa distribusi dari  $\varepsilon_t$  adalah normal dengan mean 0 dan variansi 1, diperoleh hasil pemodelan menggunakan R sebagai berikut.

```

*-----*
*      GARCH Model Fit      *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : sGARCH(1,1)
Mean Model       : ARFIMA(2,0,2)
Distribution     : norm

Optimal Parameters
-----
            Estimate Std. Error   t value Pr(>|t|)
ar1    -0.769800  0.100167 -7.68517 0.000000
ar2    -0.843684  0.065945 -12.79379 0.000000
ma1     0.855153  0.079483 10.75897 0.000000
ma2     0.899005  0.079141 11.35959 0.000000
omega   0.000000  0.000000  0.20962 0.833965
alpha1   0.007469  0.002982  2.50474 0.012254
beta1   0.985724  0.002916 338.07753 0.000000

Robust Standard Errors:
            Estimate Std. Error   t value Pr(>|t|)
ar1    -0.769800  0.268507 -2.866963 0.004144
ar2    -0.843684  0.193217 -4.366504 0.000013
ma1     0.855153  0.211081  4.051295 0.000051
ma2     0.899005  0.203785  4.411533 0.000010
omega   0.000000  0.000021  0.003804 0.996965
alpha1   0.007469  0.004279  1.745197 0.080951
beta1   0.985724  0.022070 44.664043 0.000000

LogLikelihood : 2619.128

Information Criteria
-----
Akaike        -8.4262
Bayes         -8.3762
Shibata       -8.4265
Hannan-Quinn -8.4068

Weighted Ljung-Box Test on Standardized Residuals
-----
                           statistic p-value
Lag[1]                      0.06866  0.7933
Lag[2*(p+q)+(p+q)-1][11]    4.86350  0.9764
Lag[4*(p+q)+(p+q)-1][19]    9.34757  0.5792
d.o.f=4
H0 : No serial correlation

```

Gambar 2.9. Pemodelan GARCH(1,1) menggunakan asumsi normal, halaman 1

```

Weighted Ljung-Box Test on Standardized Squared Residuals
-----
                           statistic p-value
Lag[1]                  3.431 0.06399
Lag[2*(p+q)+(p+q)-1][5] 4.338 0.21485
Lag[4*(p+q)+(p+q)-1][9] 5.572 0.35043
d.o.f=2

Weighted ARCH LM Tests
-----
                           Statistic Shape Scale P-Value
ARCH Lag[3]    0.05369 0.500 2.000  0.8168
ARCH Lag[5]    0.58380 1.440 1.667  0.8586
ARCH Lag[7]    1.68040 2.315 1.543  0.7845

Nyblom stability test
-----
Joint Statistic: 185.7406
Individual Statistics:
ar1      0.06275
ar2      0.07484
ma1      0.08540
ma2      0.15004
omega   74.51689
alpha1   0.19725
beta1   0.25686

Asymptotic Critical values (10% 5% 1%)
Joint Statistic:      1.69 1.9 2.35
Individual Statistic: 0.35 0.47 0.75

Sign Bias Test
-----
                     t-value prob sig
Sign Bias          0.8430 0.3996
Negative Sign Bias 1.4324 0.1525
Positive Sign Bias 0.8099 0.4183
Joint Effect       5.4400 0.1423

Adjusted Pearson Goodness-of-Fit Test:
-----
      group statistic p-value(g-1)
1     20      43.61    0.0010680
2     30      57.23    0.0013497
3     40      58.71    0.0221565
4     50      86.77    0.0007119

Elapsed time : 0.08515

```

**Gambar 2.10.** Pemodelan GARCH(1,1) menggunakan asumsi normal, halaman 2

Perhatikan bahwa di halaman pertama output R tersebut, setiap parameter tampak signifikan saat digunakan standar error biasa, kecuali parameter  $\omega$ . Meskipun demikian jika digunakan standar error robust, maka ternyata parameter  $\alpha_1$  juga tidak signifikan dengan p-value yang lebih dari 0.08. Hal ini mengimplikasikan adanya kemungkinan bahwa parameter  $\alpha_1$  ternyata tidak diperlukan. Kemudian, perhatikan bahwa uji Ljung-Box pada residual terstandarisasi dan kuadrat dari residual terstandarisasi keduanya tidak memberikan hasil yang signifikan, yang berarti tidak ada residual yang saling berkorelasi. Selanjutnya, uji LM juga tidak memberikan hasil yang signifikan, yang berarti tidak ada lagi volatilitas atau variansi bersyarat ARCH yang berarti. Lebih lanjut, uji Sign Bias dan uji Goodness-of-Fit Pearson juga menunjukkan bahwa tidak ada ketidaksimetrisan dalam error, dan bahwa residual sudah cocok dengan distribusi normal yang diasumsikan. Namun, ternyata uji stabilitas Nyblom tidak memberikan hasil yang baik, yaitu 185.7406 yang jauh melebihi nilai kritis 5% yaitu 1.9. Ketidakstabilitas bersama ini disebabkan oleh tingginya statistik dari parameter  $\omega$  yang bernilai 74.51689. Hal ini berarti terdapat kecenderungan  $\omega$  untuk tidak stabil dan berubah-ubah seiring berjalannya waktu. Statistik uji yang sangat tinggi berarti kecenderungan ini sangat signifikan.

Secara keseluruhan, menggunakan asumsi normal, model GARCH(1,1) yang telah digunakan sudah cukup cocok karena memenuhi banyak uji hipotesis yang dilakukan. Meskipun demikian, karena kurangnya signifikansi dari parameter  $\alpha_1$  dan ketidakstabilan parameter  $\omega$ , akan dicoba untuk menggunakan distribusi lain, seperti distribusi Student's t yang lebih tajam di mean.

Menggunakan asumsi bahwa  $\varepsilon_t$  mengikuti distribusi Student's t, diperoleh output R sebagai berikut.

```

*          GARCH Model Fit      *
*-----*

Conditional Variance Dynamics
-----
GARCH Model      : sGARCH(1,1)
Mean Model       : ARFIMA(2,0,2)
Distribution     : std

Optimal Parameters
-----
            Estimate Std. Error t value Pr(>|t|)
ar1    -0.064448   0.220830 -0.29185 0.770406
ar2    -0.753387   0.151387 -4.97657 0.000001
ma1     0.106996   0.263600  0.40590 0.684815
ma2     0.670547   0.159120  4.21410 0.000025
omega   0.000003   0.000000 13.47659 0.000000
alpha1   0.104047   0.023003  4.52311 0.000006
beta1   0.684688   0.048447 14.13284 0.000000
shape    4.389226   0.796899  5.50788 0.000000

Robust Standard Errors:
            Estimate Std. Error t value Pr(>|t|)
ar1    -0.064448   0.415759 -0.15501 0.876811
ar2    -0.753387   0.261595 -2.87998 0.003977
ma1     0.106996   0.499930  0.21402 0.830531
ma2     0.670547   0.265519  2.52542 0.011556
omega   0.000003   0.000000 10.77361 0.000000
alpha1   0.104047   0.028020  3.71326 0.000205
beta1   0.684688   0.049655 13.78881 0.000000
shape    4.389226   0.955346  4.59438 0.000004

LogLikelihood : 2646.547

Information Criteria
-----
Akaike        -8.5114
Bayes         -8.4543
Shibata       -8.5118
Hannan-Quinn -8.4892

Weighted Ljung-Box Test on Standardized Residuals
-----
                           statistic  p-value
Lag[1]                      2.250 0.1335870
Lag[2*(p+q)+(p+q)-1][11]    8.183 0.0005049
Lag[4*(p+q)+(p+q)-1][19]    11.049 0.3070267
d.o.f=4
H0 : No serial correlation

```

Gambar 2.11. Pemodelan GARCH(1,1) menggunakan asumsi distribusi t, halaman 1

```

Weighted Ljung-Box Test on Standardized Squared Residuals
-----
                           statistic p-value
Lag[1]                  0.06529  0.7983
Lag[2*(p+q)+(p+q)-1][5] 0.73458  0.9162
Lag[4*(p+q)+(p+q)-1][9] 1.81019  0.9264
d.o.f=2

Weighted ARCH LM Tests
-----
                     statistic Shape Scale P-Value
ARCH Lag[3]      0.4816 0.500 2.000  0.4877
ARCH Lag[5]      1.4439 1.440 1.667  0.6072
ARCH Lag[7]      1.8907 2.315 1.543  0.7405

Nyblom stability test
-----
Joint Statistic: 31.0592
Individual statistics:
ar1   0.03976
ar2   0.20062
ma1   0.03845
ma2   0.16955
omega 3.06534
alpha1 0.12040
beta1  0.17351
shape   0.19862

Asymptotic Critical values (10% 5% 1%)
Joint Statistic:      1.89 2.11 2.59
Individual Statistic: 0.35 0.47 0.75

Sign Bias Test
-----
            t-value prob sig
Sign Bias       0.7174 0.4734
Negative Sign Bias 0.4877 0.6259
Positive Sign Bias 1.1431 0.2534
Joint Effect     1.5736 0.6654

Adjusted Pearson Goodness-of-Fit Test:
-----
      group statistic p-value(g-1)
1    20      27.81    0.08722
2    30      45.32    0.02737
3    40      49.03    0.13029
4    50      58.23    0.17219

```

**Gambar 2.12.** Pemodelan GARCH(1,1) menggunakan asumsi distribusi t, halaman 2

Pada output R ini, ternyata kali ini diperoleh hasil bahwa parameter  $\phi_1$  dan  $\theta_1$  tidak signifikan. Lebih lanjut, meskipun uji Ljung-Box untuk lag lainnya sama, tetapi khusus untuk lag 11, hipotesis bahwa tidak terdapat autokorelasi antar residual terstandarisasi ditolak. Selain itu, uji stabilitas Nyblom juga masih mengatakan bahwa parameter  $\omega$  tidak stabil, serta kali ini bahkan uji Goodness-of-Fit Pearson signifikan berbeda dari distribusi t untuk group 30. Meskipun kriteria-kriteria informasi (AIC, BIC, SBC, HQC) untuk asumsi ini lebih kecil daripada kriteria-kriteria pada asumsi distribusi normal, ternyata muncul banyak permasalahan baru yang perlu diselesaikan. Hal ini berarti model GARCH(1,1) yang mengasumsikan distribusi t tidak sebaik menggunakan asumsi distribusi normal.

Selanjutnya, akan dicoba untuk memodelkan volatilitas ini menggunakan distribusi *Generalized Error Distribution* (GED), yang memiliki pdf

$$f(x; v) = \frac{v}{\lambda 2^{(1+1/v)} \Gamma(1/v)} \exp\left(-\frac{1}{2} \left|\frac{x}{\lambda}\right|^v\right)$$

dengan

$$\lambda = \sqrt{\frac{2^{-2/v} \Gamma(1/v)}{\Gamma(3/v)}}.$$

Distribusi ini memiliki mean nol dan variansi 1, sehingga bisa digunakan sebagai asumsi untuk distribusi dari  $\varepsilon_t$ . Menggunakan asumsi distribusi GED, diperoleh hasil output R sebagai berikut.

```

*          GARCH Model Fit      *
*-----*
Conditional variance Dynamics
-----
GARCH Model      : sGARCH(1,1)
Mean Model       : ARFIMA(2,0,2)
Distribution     : ged

Optimal Parameters
-----
            Estimate Std. Error   t value Pr(>|t|)
ar1    -1.386160  0.004716 -293.9201 0.000000
ar2    -0.870486  0.054223  -16.0537 0.000000
ma1     1.419043  0.009949  142.6319 0.000000
ma2     0.908214  0.053813   16.8771 0.000000
omega   0.000004  0.000000   44.7013 0.000000
alpha1   0.103523  0.033414    3.0982 0.001947
beta1   0.598709  0.048948   12.2314 0.000000
shape    1.076327  0.072216   14.9042 0.000000

Robust Standard Errors:
            Estimate Std. Error   t value Pr(>|t|)
ar1    -1.386160  0.047009 -29.4869 0.00000
ar2    -0.870486  0.098474  -8.8397 0.00000
ma1     1.419043  0.030996  45.7809 0.00000
ma2     0.908214  0.102350   8.8736 0.00000
omega   0.000004  0.000000  47.2433 0.00000
alpha1   0.103523  0.038859   2.6641 0.00772
beta1   0.598709  0.051140  11.7072 0.00000
shape    1.076327  0.102979  10.4519 0.00000

LogLikelihood : 2648.406

Information Criteria
-----
Akaike        -8.5174
Bayes         -8.4603
Shibata       -8.5178
Hannan-Quinn -8.4952

Weighted Ljung-Box Test on Standardized Residuals
-----
                           statistic   p-value
Lag[1]                      2.187 1.392e-01
Lag[2*(p+q)+(p+q)-1][11]    10.719 6.737e-11
Lag[4*(p+q)+(p+q)-1][19]    15.628 1.789e-02
d.o.f=4
H0 : No serial correlation

```

**Gambar 2.13.** Pemodelan GARCH(1,1) menggunakan asumsi distribusi GED, halaman 1

```

Weighted Ljung-Box Test on Standardized Squared Residuals
-----
                           statistic p-value
Lag[1]                  0.1824  0.6693
Lag[2*(p+q)+(p+q)-1][5] 0.5790  0.9448
Lag[4*(p+q)+(p+q)-1][9] 1.4142  0.9623
d.o.f=2

Weighted ARCH LM Tests
-----
                    Statistic Shape Scale P-Value
ARCH Lag[3]      0.1901 0.500 2.000  0.6628
ARCH Lag[5]      0.8655 1.440 1.667  0.7732
ARCH Lag[7]      1.4369 2.315 1.543  0.8339

Nyblom stability test
-----
Joint Statistic: 9.6587
Individual Statistics:
ar1   0.2604
ar2   0.4567
ma1   0.1614
ma2   0.3460
omega 2.2398
alpha1 0.1288
beta1  0.1704
shape   0.2398

Asymptotic Critical Values (10% 5% 1%)
Joint Statistic:      1.89 2.11 2.59
Individual Statistic: 0.35 0.47 0.75

Sign Bias Test
-----
                t-value prob sig
Sign Bias        0.5150 0.6068
Negative Sign Bias 0.1933 0.8468
Positive Sign Bias 1.3329 0.1831
Joint Effect     1.9871 0.5751

Adjusted Pearson Goodness-of-Fit Test:
-----
    group statistic p-value(g-1)
1    20      21.29      0.3210
2    30      31.00      0.3654
3    40      42.84      0.3099
4    50      51.61      0.3720

```

**Gambar 2.14.** Pemodelan GARCH(1,1) menggunakan asumsi distribusi GED, halaman 2

Kali ini, perhatikan bahwa:

- Seluruh parameter yang digunakan dan diestimasi signifikan, baik dengan menggunakan standar error biasa maupun menggunakan standar error robust.
- Nilai-nilai kriteria-kriteria informasi AIC, BIC, SBC, dan HQC lebih rendah dibandingkan kedua model sebelumnya.
- Uji Ljung-Box tidak signifikan kecuali pada lag 11 untuk residual terstandarisasi. Hal ini juga terjadi di model yang mengasumsikan distribusi t.
- Uji LM ARCH tidak signifikan, yang berarti tidak ada unsur ARCH tambahan.
- Uji stabilitas Nyblom kali ini setidaknya memiliki statistik uji yang lebih rendah dibandingkan dengan model sebelumnya, meskipun masih memiliki parameter  $\omega$  yang kurang stabil.
- Uji Sign Bias tidak menandakan adanya ketidaksimetrisan pada error.
- Uji Goodness-of-Fit Pearson menandakan adanya kecocokan antara error dengan asumsi GED.

Semua ini menunjukkan bahwa model ini adalah model yang lebih baik dibandingkan dengan kedua model sebelumnya. Oleh karena itu, model akhir yang akan digunakan untuk runtun waktu ini adalah

$$r_t = -1.386160r_{t-1} - 0.870486r_{t-2} + e_t + 1.419043e_{t-1} + 0.908214e_{t-2}$$

dimana  $e_t$  berdistribusi identik dan independen dengan mean nol dan variansi bersyarat atau volatilitas

$$\sigma_{t|t-1}^2 = 0.000004 + 0.103523e_{t-1}^2 + 0.598709\sigma_{t-1|t-2}^2$$

serta

$$e_t = \varepsilon_t \sigma_{t|t-1}$$

dengan  $\varepsilon_t \sim GED(\nu = 1.076327)$  memiliki mean 0 dan variansi 1.

### 2.2.2 Analisis Residual

Setelah diperoleh model ARMA(2,2) dengan GARCH(1,1) untuk memodelkan return, perlu dilakukan juga analisis residual untuk memeriksa kecocokan model. Memang sudah dilihat beberapa pengujian numerik, seperti uji LM untuk ARCH yang menyatakan tidak adanya efek ARCH tambahan pada volatilitas, uji autokorelasi Ljung-Box yang menyatakan tidak adanya autokorelasi yang terlalu signifikan pada model, dan juga uji Goodness-of-Fit Pearson yang menyatakan kecocokan error dengan distribusi GED, analisis residual berupa visualisasi juga penting untuk dilakukan untuk meyakinkan dan meneguhkan model yang telah diperoleh.

Untuk melakukan analisis residual ini, pertama dihitung residual untuk model menggunakan R. Residual ini dapat dihitung dengan

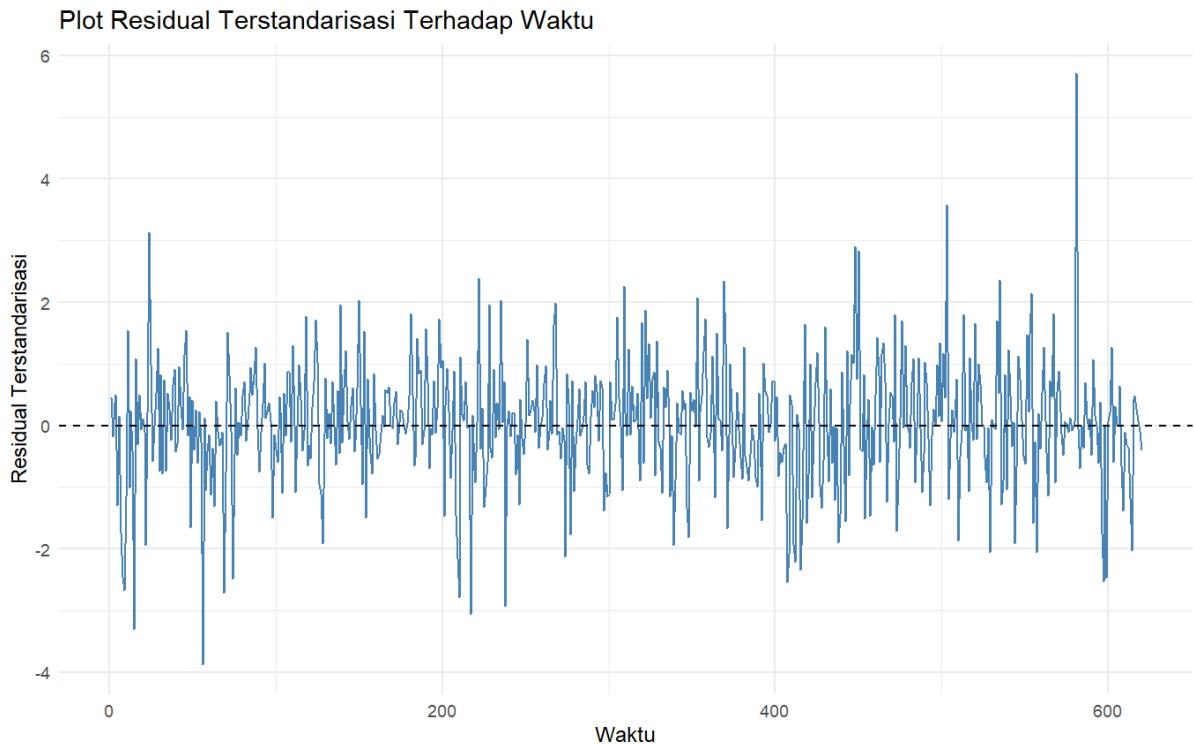
$$e_t = r_t - \hat{r}_t$$

dimana  $\hat{r}_t$  diperoleh dari melakukan “peramalan” pada  $r_t$ . Setelah diperoleh series residual ini, dihitung juga residual terstandarisasi, yaitu

$$\varepsilon_t = e_t / \sigma_t$$

yang akan memiliki skala standar deviasi yang biasa. Residual terstandarisasi inilah yang akan digunakan untuk melakukan analisis residual.

Setelah mendapatkan runtun waktu residual terstandarisasi, dibuat plot residual terstandarisasi ini terhadap waktu. Menggunakan R, didapat plot sebagai berikut.

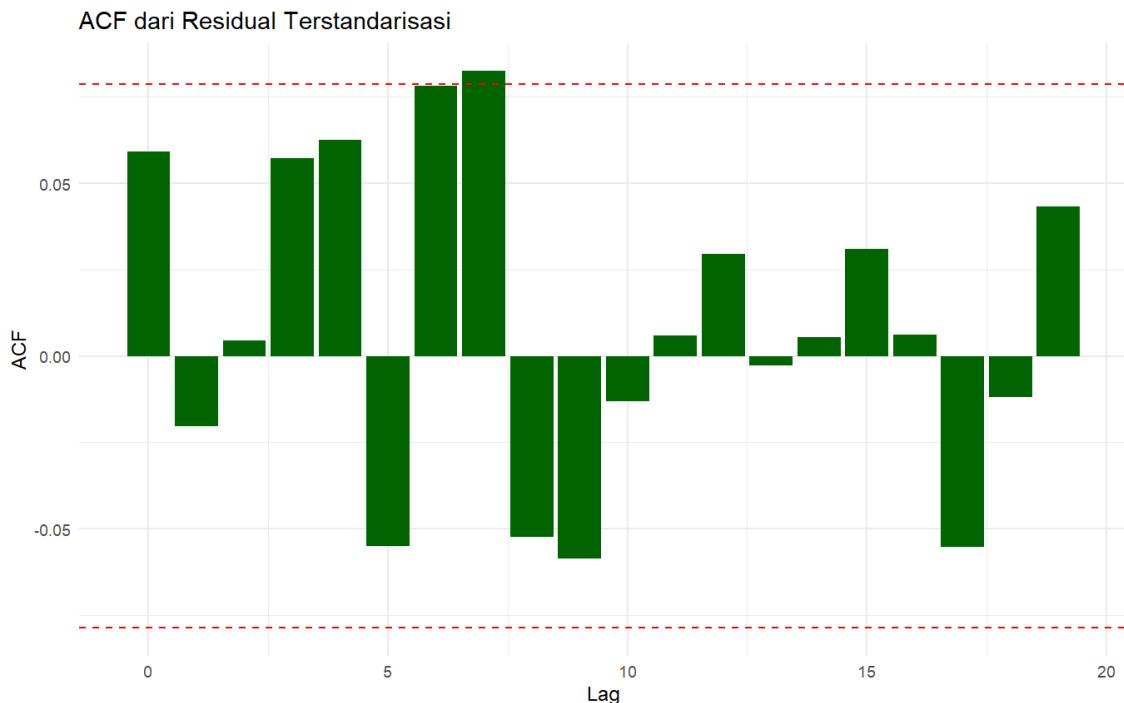


**Gambar 2.15.** Plot residual terstandarisasi terhadap waktu

Perhatikan bahwa ternyata residual terstandarisasi tidak memiliki pola tertentu dan menyerupai white noise. Meskipun demikian, penting untuk dilihat bahwa residual terstandarisasi ini cenderung lebih menyebar dibandingkan dengan plot residual terstandarisasi biasa, dimana disini residual terstandarisasinya seringkali mencapai nilai lebih dari 2, 3 atau bahkan mencapai mendekati 6. Meskipun demikian, hal ini sebenarnya merupakan hasil output yang diharapkan, karena distribusi dari  $\varepsilon_t$  memang diasumsikan untuk mengikuti distribusi GED dengan parameter  $v$  kecil, yaitu 1.076327. Distribusi GED, terutama untuk  $v$  yang kecil, memang cenderung memiliki persebaran yang lebih besar dibandingkan dengan distribusi normal yang jarang tersebar lebih atau kurang dari 2.

Selain melakukan plot untuk residual terstandarisasi terhadap waktu, umumnya juga dilakukan plot ACF dari residual terstandarisasi dan juga plot ACF dari kuadrat dari residual terstandarisasi. Hal ini dilakukan untuk memeriksa keberadaan autokorelasi pada residual. Meskipun sudah dilakukan uji Ljung-Box untuk keseluruhan lag, plot ACF juga penting dilakukan sebagai visualisasi dan juga untuk memeriksa masing-masing lag.

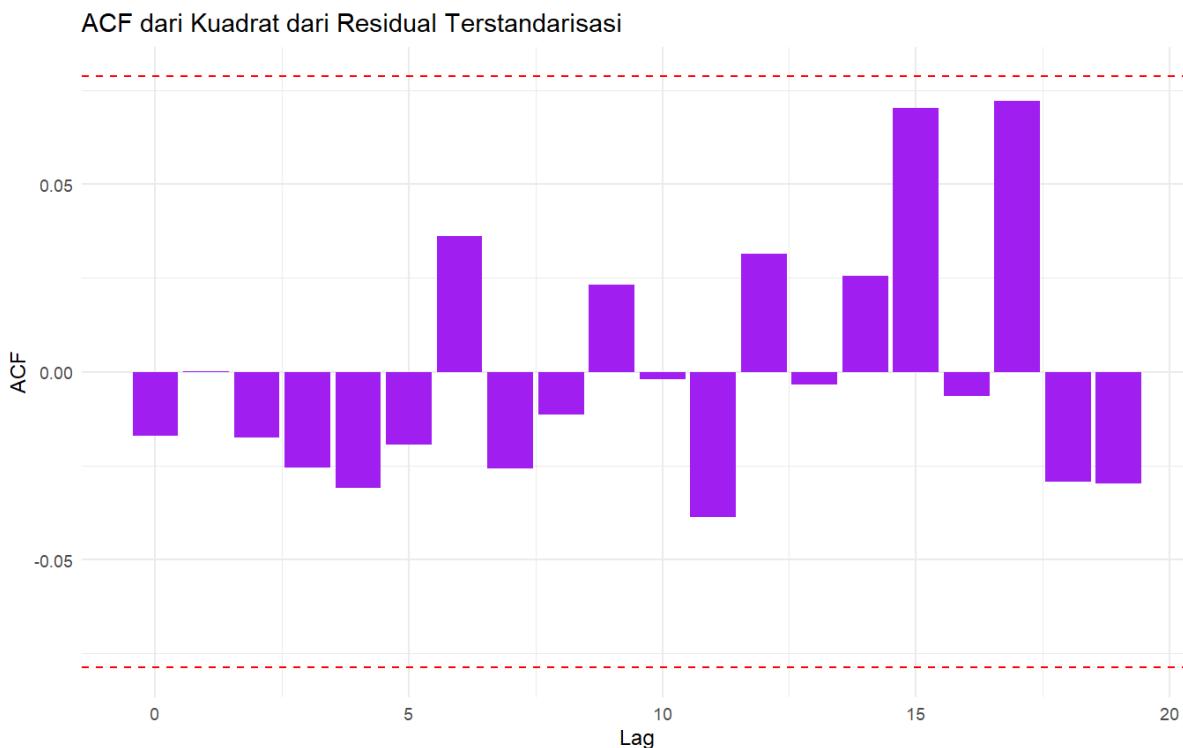
Menggunakan R, diperoleh plot ACF untuk setiap lag dari lag 1 sampai lag 20 untuk residual terstandarisasi ini, yaitu sebagai berikut.



**Gambar 2.16.** Plot ACF dari residual terstandarisasi

Perhatikan bahwa selain pada lag 6-7, semua ACF lain tidak signifikan berada di luar garis kritis penolakan. Penolakan pada lag 6-7 ini bisa terjadi kemungkinan karena adanya outlier, atau karena kecenderungan data untuk memiliki hubungan kecil setelah tepat 7 hari atau 1 minggu berlalu. Meskipun demikian, signifikansi lag 7 ini tidak akan dianggap terlalu berpengaruh karena tidak ada lag lain yang memiliki ACF signifikan. Selain itu, plot ini juga tidak memiliki pola apapun, sehingga cocok untuk menjadi plot ACF.

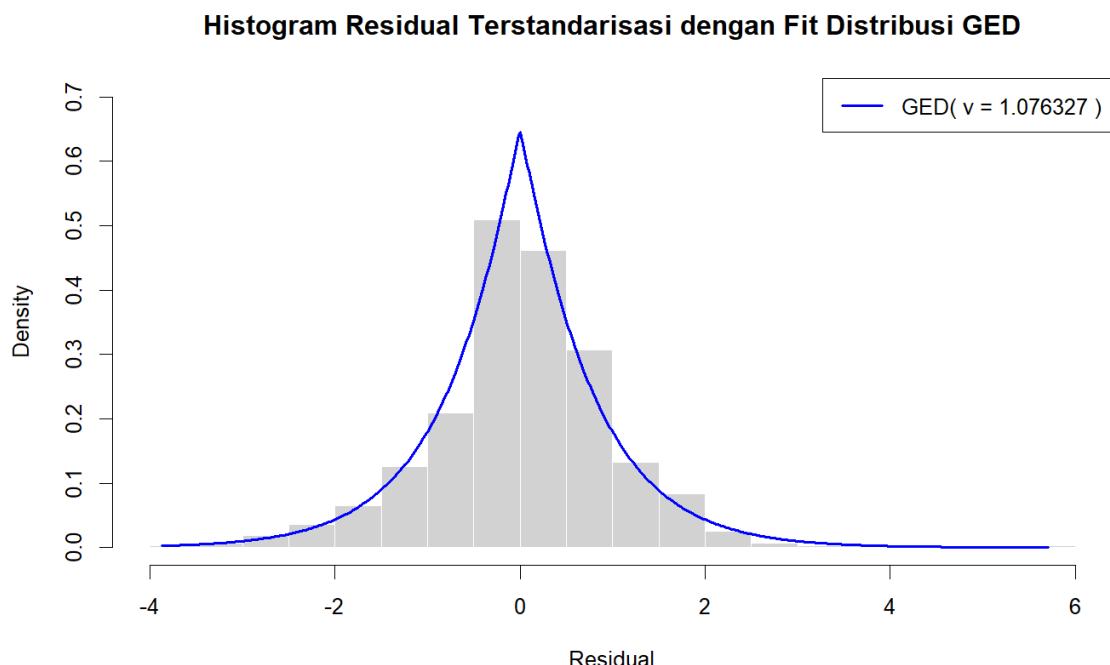
Plot ACF juga dapat dilakukan pada kuadrat dari residual terstandarisasi. Menggunakan R, diperoleh plot ACF berikut untuk kuadrat dari residual terstandarisasi.



**Gambar 2.17.** Plot ACF dari kuadrat dari residual terstandarisasi

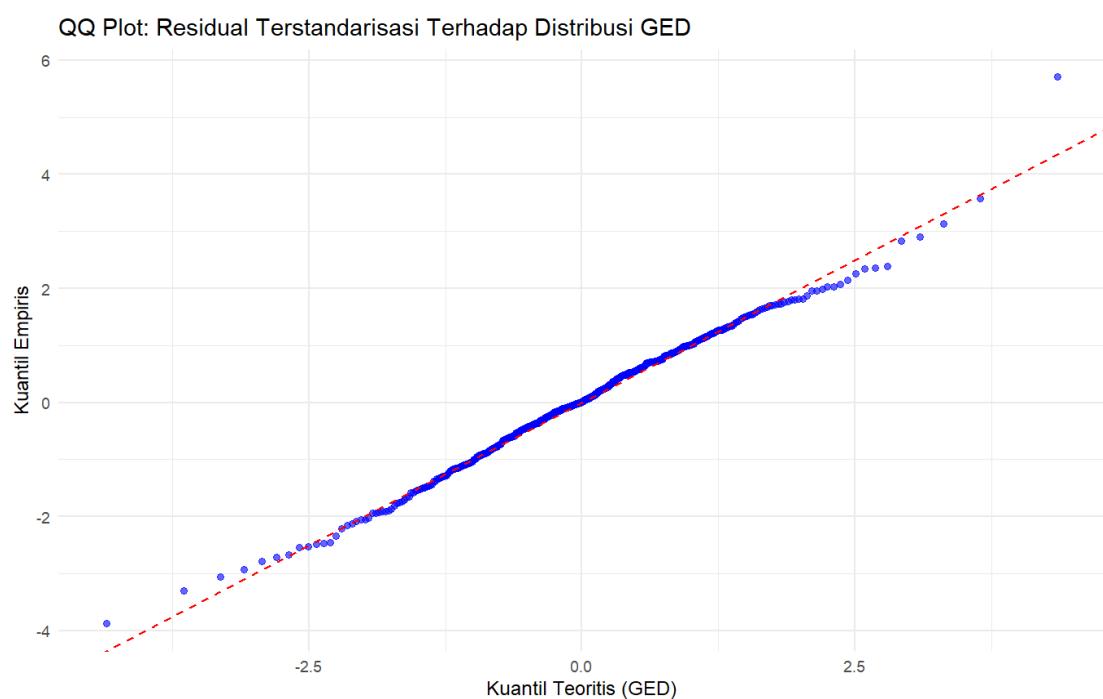
Untuk plot ini, hasil ACF lagi-lagi tidak memiliki pola yang signifikan dan juga tidak ada lag yang memiliki nilai ACF signifikan melebihi garis penolakan. Oleh karena itu, bisa disimpulkan bahwa memang tidak terdapat autokorelasi pada residual, baik residual terstandarisasi maupun kuadrat dari residual terstandarisasi. Hal ini juga sejalan dengan output uji Ljung-Box yang telah dihitung sebelumnya.

Selanjutnya, langkah analisis residual yang dapat dilakukan adalah memeriksa kecocokan residual dengan distribusi asumsi. Pengujian ini sebenarnya sudah dilakukan lewat uji Goodness-of-Fit Pearson, yang memberikan hasil yang baik, tetapi visualisasi menggunakan plot bisa membantu untuk mendukung hasil numerik tersebut. Terdapat beberapa cara visualisasi yang dapat dilakukan, dan pada laporan ini akan ditunjukkan dua cara. Yang pertama yaitu menggunakan histogram dari residual terstandarisasi sebagai estimasi nonparametrik untuk distribusi dari residual terstandarisasi ini, dimana histogram ini akan dibandingkan dengan distribusi GED asumsi sebenarnya. Menggunakan R, diperoleh visualisasi sebagai berikut.



**Gambar 2.18.** Histogram residual terstandarisasi yang dibandingkan dengan distribusi  $\text{GED}(v = 1.076327)$

Perhatikan bahwa histogram cukup cocok dengan distribusi GED, sehingga tidak ada masalah dalam visualisasi ini. Kemudian, bisa juga dilakukan visualisasi menggunakan QQ-plot, tetapi bukan QQ-plot distribusi normal melainkan QQ-plot dengan distribusi GED sebagai berikut.



**Gambar 2.19.** QQ Plot residual terstandarisasi terhadap distribusi GED

Perhatikan bahwa titik-titik tersebut tidak berbeda terlalu jauh dari garis lurus, dan meskipun terdapat outlier secara tiba-tiba di akhir, outlier ini hanya berjumlah satu, dan tidak akan dianggap signifikan.

Hal ini berarti residual terstandarisasi juga sudah bersifat baik dalam mengikuti distribusi asumsi. Bersama dengan hasil-hasil analisis residual lainnya, yaitu tidak adanya pola yang jelas antara residual dengan waktu dan juga tidak adanya autokorelasi antar residual di setiap lag, dapat disimpulkan bahwa residual dari model yang telah diperoleh berperilaku baik dan lebih lanjut berarti model ARMA(2,2)-GARCH(1,1) dapat diterima dengan baik.

### 2.2.3 Peramalan

Setelah mendapatkan model terbaik yang diverifikasi menggunakan analisis residual, selanjutnya akan dilakukan peramalan atau *forecasting*. Karena digunakan model gabungan ARIMA dan GARCH, maka peramalan yang dapat dilakukan ada dua macam, yaitu peramalan pada mean/tren menggunakan ARIMA dan peramalan pada volatilitas menggunakan GARCH. Kedua peramalan ini dapat digunakan untuk melakukan peramalan pada runtun waktu return.

Untuk melakukan peramalan pada model return yang telah dibangun, yaitu

$$r_t = -1.386160r_{t-1} - 0.870486r_{t-2} + e_t + 1.419043e_{t-1} + 0.908214e_{t-2},$$

cukup mengganti setiap  $t$  dengan  $t + l$  menjadi

$$r_{t+l} = -1.386160r_{t+l-1} - 0.870486r_{t+l-2} + e_{t+l} + 1.419043e_{t+l-1} + 0.908214e_{t+l-2}$$

kemudian mengambil ekspektasi bersyaratnya diketahui informasi  $r_1, r_2, \dots, r_t$  pada kedua ruas. Secara khusus, untuk peramalan 1 langkah ke depan, yaitu  $l = 1$ , modelnya menjadi

$$r_{t+1} = -1.386160r_t - 0.870486r_{t-1} + e_{t+1} + 1.419043e_t + 0.908214e_{t-1}$$

dan jika diambil ekspektasi bersyarat, diperoleh

$$E(r_{t+1}|r_t, \dots, r_1) = -1.386160r_t - 0.870486r_{t-1} + 1.419043e_t + 0.908214e_{t-1}$$

atau

$$\hat{r}_t(1) = -1.386160r_t - 0.870486r_{t-1} + 1.419043e_t + 0.908214e_{t-1}.$$

Peramalan untuk beberapa step ke depan lainnya juga bisa dilakukan dengan cara yang mirip. Sebagai contoh, untuk 2 step ke depan diperoleh

$$\hat{r}_t(2) = -1.386160\hat{r}_t(1) - 0.870486r_t + 0.908214e_t$$

dan untuk step  $l > 2$  diperoleh

$$\hat{r}_t(l) = -1.386160\hat{r}_t(l-1) - 0.870486\hat{r}_t(l-2).$$

Model ini saja sebenarnya sudah cukup untuk memperoleh peramalan untuk beberapa waktu ke depan. Tetapi, interval kepercayaan dari peramalan belum bisa diperoleh, karena belum ada kejelasan mengenai variansi dari peramalan, karena variansi tersebut dijelaskan oleh volatilitas yang dimodelkan oleh GARCH(1,1). Oleh karena itu, perlu juga dilakukan peramalan pada volatilitas atau variansi bersyarat.

Untuk melakukan peramalan pada volatilitas, ingat kembali bahwa term error pada model, yaitu  $e_t$ , memiliki bentuk

$$e_t = \varepsilon_t \sigma_{t|t-1}$$

dimana  $\varepsilon_t$  saling independen dan berdistribusi GED identik dengan mean nol dan variansi 1, dan  $\sigma_{t|t-1}^2 = 0.000004 + 0.103523e_{t-1}^2 + 0.598709\sigma_{t-1|t-2}^2$ . Akibatnya,  $e_t$  juga memiliki bentuk kuadrat

$$e_t^2 = \varepsilon_t^2 \sigma_{t|t-1}^2$$

sehingga ekspektasi dari  $e_t^2$  adalah  $\sigma_{t|t-1}^2$ . Menggunakan informasi ini, dapat ditentukan peramalan untuk volatilitas, lagi-lagi dengan mengganti  $t$  dengan  $t + l$ , sehingga diperoleh

$$\sigma_{t+l|t+l-1}^2 = 0.000004 + 0.103523e_{t+l-1}^2 + 0.598709\sigma_{t+l-1|t+l-2}^2.$$

Secara khusus, untuk  $l = 1$ ,

$$\sigma_{t+1|t}^2 = 0.000004 + 0.103523e_t^2 + 0.598709\sigma_{t|t-1}^2$$

dan jika diambil ekspektasi bersyarat, diperoleh peramalan

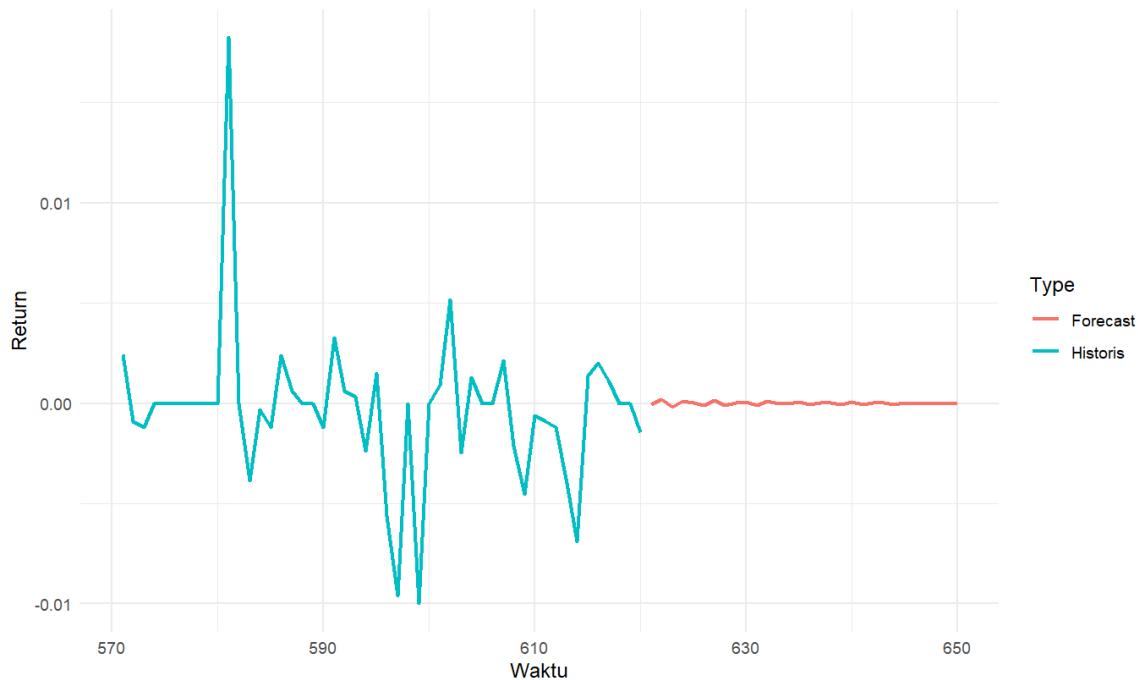
$$E(\sigma_{t+1|t}^2 | \mathcal{F}_t) = \hat{\sigma}_{t+1|t}^2 = 0.000004 + 0.103523e_t^2 + 0.598709\sigma_{t|t-1}^2.$$

Untuk step kedua dan seterusnya, dengan cara yang mirip diperoleh peramalan

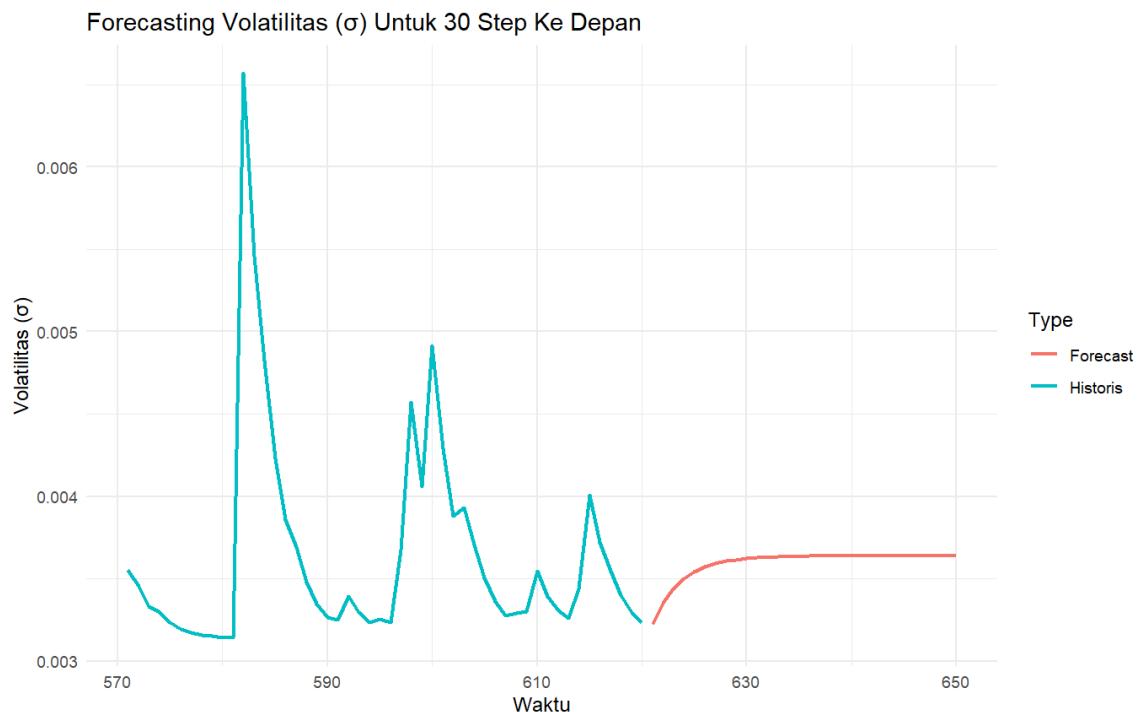
$$\hat{\sigma}_{t+l|t+l-1}^2 = 0.000004 + 0.702232\hat{\sigma}_{t+l-1|t+l-2}^2.$$

Menggunakan kedua metode peramalan ini, bisa dilakukan peramalan untuk beberapa step ke depan dari data yang dimiliki, lengkap dengan interval kepercayaan 95% nya. Peramalan ini bisa saja dilakukan secara manual, tetapi akan lebih mudah jika dilakukan menggunakan program seperti R. Menggunakan program R, diperoleh hasil peramalan sebagai berikut.

Forecasting Return Untuk 30 Step Ke Depan

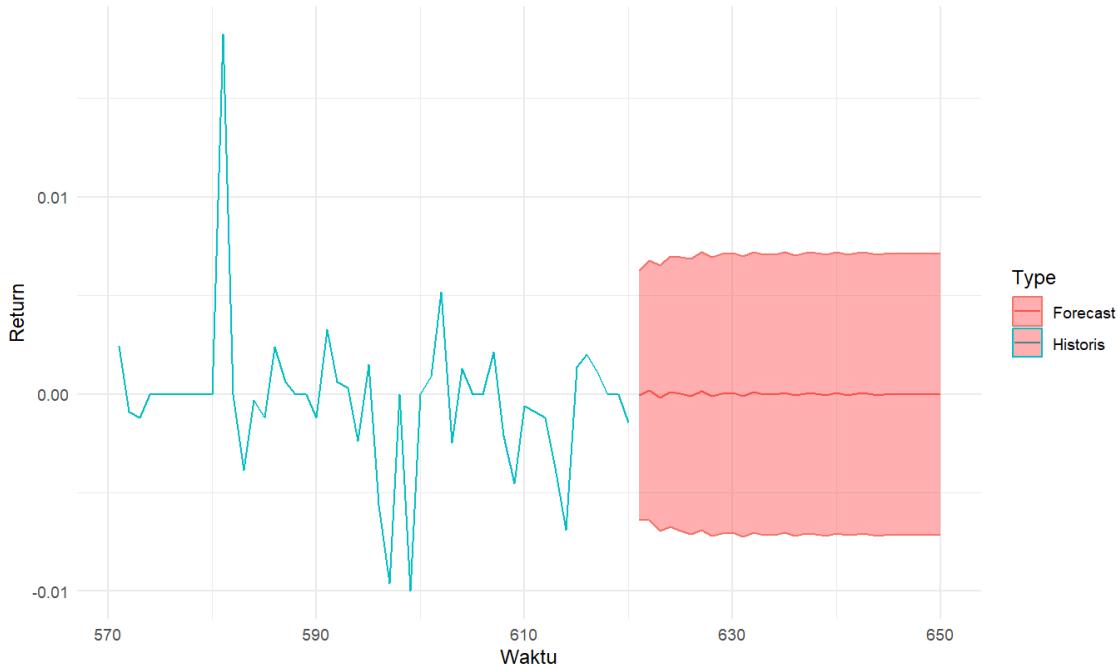


**Gambar 2.20.** Plot peramalan tren/mean untuk 30 langkah ke depan, menggunakan model ARMA(2,2)



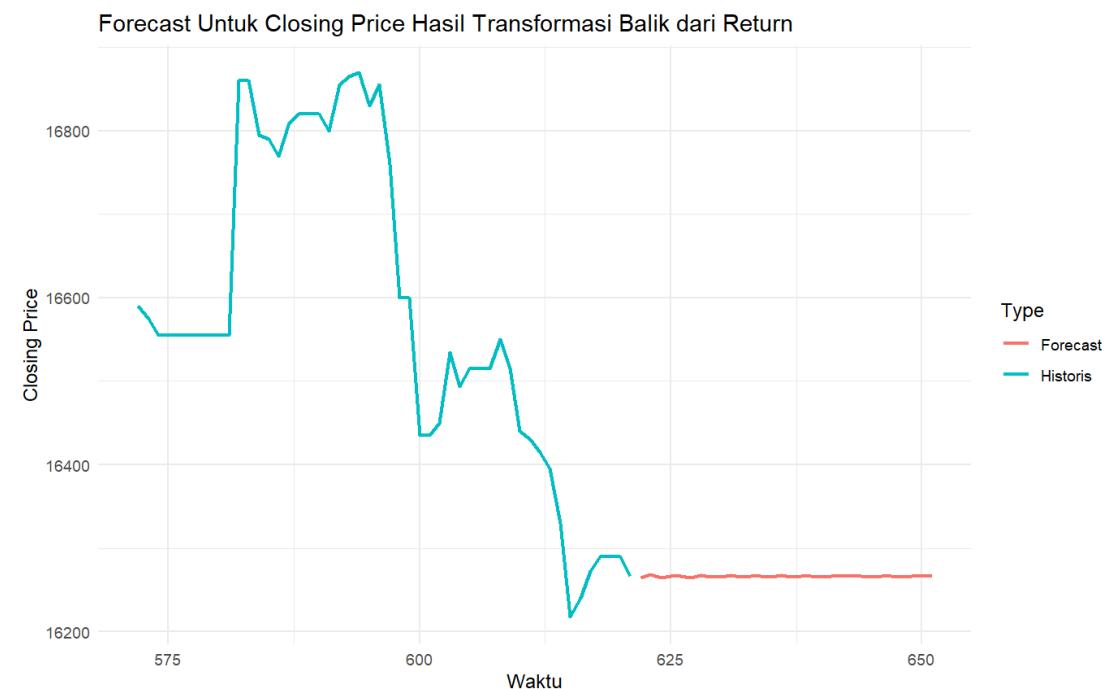
**Gambar 2.21.** Plot peramalan volatilitas ( $\sigma_t$ ) untuk 30 langkah ke depan, menggunakan model GARCH(1,1)

Forecasting Return untuk 30 Step Ke Depan Beserta Interval Kepercayaan



**Gambar 2.22.** Plot peramalan tren/mean untuk 30 langkah ke depan menggunakan model ARMA(2,2) beserta interval kepercayaan 95% yang volatilitas atau variansi bersyaratnya dimodelkan oleh GARCH(1,1)

Selanjutnya, setelah diperoleh hasil forecast 30 langkah tersebut, tentu data bisa saja ditransformasi kembali menjadi *closing price*. Hasil transformasi balik pada peramalan memberikan hasil plot sebagai berikut.



**Gambar 2.23.** Plot peramalan untuk *closing prices* selama 30 langkah ke depan

Meskipun demikian, perlu berhati-hati dalam menggunakan hasil peramalan ini, karena peramalan ini memiliki variansi yang kurang jelas, yang mengakibatkan tidak adanya interval kepercayaan yang baik untuk peramalan ini. Selain itu, dapat dilihat juga bahwa hasil peramalan cenderung stabil. Hal ini tidak cocok dengan sifat dari data yang dimiliki juga, dimana pasti di antara peramalan ini akan terjadi kenaikan atau penurunan yang besar pada *closing prices*.

## BAB III

### INTERPRETASI

#### 3.1 Interpretasi Model ARMA(2,2)-GARCH(1,1)

##### 3.1.1 Interpretasi Komponen ARMA(2,2)

Berdasarkan hasil estimasi yang telah dilakukan, model ARMA(2,2) yang diperoleh untuk menjelaskan dinamika return nilai tukar USD/IDR menunjukkan karakteristik yang sangat menarik dan bermakna secara ekonomi. Model yang diestimasi memiliki persamaan

$$r_t = -1.386160r_{t-1} - 0.870486r_{t-2} + e_t + 1.419043e_{t-1} + 0.908214e_{t-2},$$

di mana seluruh parameter menunjukkan signifikansi statistik yang kuat.

Interpretasi dari komponen autoregressive (AR) mengungkapkan fenomena ekonomi yang sangat penting dalam dinamika nilai tukar. Koefisien  $\varphi_1 = -1.386160$  yang bernilai negatif dan signifikan menunjukkan adanya efek pembalikan atau *mean-reverting* yang kuat pada *return* nilai tukar. Hal ini mengindikasikan bahwa ketika Rupiah mengalami apresiasi (*return* positif) pada periode sebelumnya, terdapat kecenderungan yang kuat untuk mengalami depresiasi (*return* negatif) pada periode berikutnya, dan sebaliknya. Fenomena ini konsisten dengan teori *purchasing power parity* dan fundamental *equilibrium exchange rate*, di mana nilai tukar cenderung kembali ke nilai keseimbangannya dalam jangka panjang.

Koefisien AR kedua,  $\varphi_2 = -0.870486$ , yang juga bernilai negatif, memperkuat karakteristik mean-reverting ini dengan menunjukkan bahwa efek pembalikan tidak hanya terjadi satu periode ke depan, tetapi juga memiliki dampak hingga dua periode. Ini mencerminkan bahwa pasar valuta asing IDR/USD memiliki mekanisme koreksi diri yang efektif, di mana deviasi dari nilai fundamental akan dikoreksi secara bertahap melalui mekanisme pasar.

Dari sisi komponen moving average (MA), parameter  $\theta_1 = 1.419043$  yang positif dan besar menunjukkan bahwa *shock* atau gangguan ekonomi pada periode sebelumnya memberikan dampak positif yang signifikan pada return periode ini. Nilai koefisien yang lebih besar dari satu mengindikasikan bahwa pasar valuta asing Indonesia memiliki sensitivitas yang tinggi terhadap informasi baru atau *shock* ekonomi. Parameter  $\theta_2 = 0.908214$  yang juga positif menunjukkan bahwa dampak *shock* tersebut tidak hanya berlangsung satu periode, tetapi memiliki persistensi hingga dua periode ke depan.

Secara keseluruhan, model ARMA(2,2) menunjukkan bahwa nilai tukar USD/IDR memiliki karakteristik mean-reverting, dengan pembalikan harga yang tidak hanya terbatas pada satu periode, tetapi juga mencakup dua periode ke depan. Kombinasi karakteristik autoregressive (AR) dan moving average (MA) ini menghasilkan interpretasi ekonomi yang sangat relevan dengan kondisi pasar valuta asing Indonesia. Model ini menunjukkan bahwa nilai tukar USD/IDR memiliki memori jangka pendek yang konsisten dengan teori ekonomi,

di mana nilai tukar cenderung kembali ke nilai fundamentalnya dalam jangka panjang, meskipun bisa mengalami deviasi sementara akibat faktor-faktor spekulatif, sentimen pasar, atau shock ekonomi eksternal maupun internal.

Dampak dari shock ekonomi yang terjadi di masa lalu memiliki pengaruh yang besar pada kondisi pasar saat ini, dan efeknya bisa berlangsung lebih lama dari satu periode. Hal ini mencerminkan bahwa meskipun pasar memiliki mekanisme untuk kembali ke keseimbangan, perubahan ekonomi atau kejadian tak terduga dapat mengubah laju atau kestabilan pembalikan harga tersebut. Fenomena ini mengindikasikan adanya ketahanan jangka pendek dalam pasar valuta asing Indonesia, di mana harga bergerak sesuai dengan informasi atau shock yang datang, namun dengan kecenderungan untuk kembali ke nilai dasar dalam waktu yang relatif singkat.

### 3.1.2 Interpretasi Komponen GARCH(1,1)

Model GARCH(1,1) yang digunakan untuk memodelkan volatilitas menunjukkan persamaan

$$\sigma_{t+l|t+l-1}^2 = \omega + \alpha_1 e_{t+l-1}^2 + \beta_1 \sigma_{t+l-1|t+l-2}^2.$$

Parameter konstanta  $\omega = 0.000004$  yang sangat kecil menunjukkan bahwa volatilitas dasar atau *unconditional variance* dari return nilai tukar USD/IDR dalam kondisi normal relatif rendah. Hal ini mengindikasikan bahwa dalam kondisi ekonomi yang stabil, tanpa adanya shock eksternal yang signifikan, volatilitas nilai tukar cenderung berada pada level yang rendah dan terkendali.

Parameter  $\alpha_1 = 0.103523$  menunjukkan bahwa 10.35% dari volatilitas periode ini dijelaskan oleh kuadrat residual periode sebelumnya, yang dalam konteks efek ARCH menggambarkan seberapa reaktif volatilitas terhadap shock atau berita baru. Nilai ini relatif moderat, mengindikasikan bahwa pasar valuta asing IDR/USD tidak over-reaktif terhadap informasi baru, yang mencerminkan kematiangan pasar dan efektivitas intervensi Bank Indonesia dalam menstabilkan nilai tukar.

Parameter  $\beta_1 = 0.598709$  menunjukkan persistensi volatilitas yang cukup tinggi, di mana 59.87% volatilitas periode ini dijelaskan oleh volatilitas periode sebelumnya. Nilai ini mengindikasikan adanya *memory effect* yang kuat dalam volatilitas, artinya ketika terjadi periode volatilitas tinggi, dampaknya akan bertahan untuk beberapa periode ke depan sebelum kembali ke level normal. Persistensi total  $\alpha_1 + \beta_1 = 0.702232 < 1$  mengkonfirmasi stasioneritas model GARCH dan menunjukkan bahwa volatilitas akan mengalami *mean reversion* dalam jangka panjang.

Penggunaan distribusi Generalized Error Distribution (GED) dengan parameter  $v = 1.076327$  memberikan fit yang superior dibandingkan distribusi normal atau Student's t. Parameter  $v$  yang mendekati 1 menunjukkan bahwa distribusi residual memiliki karakteristik

fat tails yang lebih ekstrem dibandingkan distribusi normal, yang konsisten dengan karakteristik data finansial yang sering mengalami kejadian ekstrem atau outlier. Distribusi GED dengan parameter ini mampu mengakomodasi *volatility clustering* dan *extreme events* yang sering terjadi dalam pasar valuta asing *emerging markets* seperti Indonesia.

Secara keseluruhan, model GARCH(1,1) berhasil menangkap karakteristik volatility clustering dan persistensi volatilitas dalam pasar valuta asing Indonesia, yang menunjukkan bahwa periode volatilitas tinggi cenderung diikuti oleh periode volatilitas tinggi, dan sebaliknya. Dengan mengasumsikan distribusi Generalized Error Distribution (GED), model ini lebih efektif dalam menangani ekor tebal (fat tails) yang mencirikan kejadian ekstrem yang sering terjadi pada pasar finansial. Hal ini sangat berguna untuk memprediksi risiko volatilitas di masa depan, karena pasar sering kali menghadapi fluktuasi harga yang tajam dan kejadian-kejadian yang tidak terduga.

Keunggulan model GARCH(1,1) dengan distribusi GED terletak pada kemampuannya untuk memprediksi volatilitas jangka pendek dengan akurat, serta memberikan gambaran lebih realistik tentang risiko dan peristiwa ekstrem yang mungkin terjadi di pasar. Model ini sangat penting untuk manajemen risiko, karena dapat memberikan wawasan yang lebih baik dalam merencanakan langkah-langkah strategis dalam menghadapi ketidakpastian pasar, serta memperkuat perencanaan risiko jangka panjang dengan lebih andal dan berbasis data yang realistik.

### 3.2 Interpretasi Validasi Model

Validasi model ARMA(2,2)-GARCH(1,1) dengan distribusi GED menunjukkan hasil yang sangat memuaskan dari berbagai aspek uji statistik yang dilakukan. Semua parameter model menunjukkan signifikansi statistik pada tingkat kepercayaan 95%, baik menggunakan standard error biasa maupun *robust standard error*. Hal ini mengkonfirmasi bahwa setiap komponen dalam model, mulai dari parameter *autoregressive*, *moving average*, hingga parameter GARCH, memberikan kontribusi yang bermakna secara statistik dalam menjelaskan dinamika data nilai tukar USD/IDR.

Perbandingan kriteria informasi menunjukkan superioritas model dengan distribusi GED. Nilai AIC = -8.5174, BIC = -8.4603, Shibata = -8.5178, dan Hannan-Quinn = -8.4952 semuanya menunjukkan nilai terbaik dibandingkan dengan model yang menggunakan distribusi normal. Hal ini mengkonfirmasi bahwa pemilihan distribusi GED tidak hanya secara teoritis masuk akal, tetapi juga secara empiris memberikan fit yang terbaik untuk data yang dimiliki.

Uji diagnostik residual memberikan hasil yang sangat mendukung validitas model. Uji Ljung-Box untuk autokorelasi residual terstandarisasi menunjukkan bahwa tidak ada autokorelasi yang signifikan pada sebagian besar lag, dengan p-value yang umumnya di atas 0.05. Hal ini mengindikasikan bahwa model ARMA(2,2) telah berhasil menangkap struktur temporal dalam mean return, sehingga residual yang dihasilkan berperilaku seperti white noise sebagaimana diharapkan dalam pemodelan deret waktu yang baik.

Uji Ljung-Box untuk kuadrat residual terstandarisasi juga menunjukkan hasil yang memuaskan, dengan tidak adanya efek ARCH yang tersisa pada sebagian besar lag. Ini mengkonfirmasi bahwa model GARCH(1,1) telah berhasil menangkap heteroskedastisitas bersyarat dalam data, sehingga varians residual telah dikondisikan dengan baik. Uji ARCH-LM lebih lanjut mendukung temuan ini dengan menunjukkan p-value di atas 0.05 untuk semua lag yang diuji, mengkonfirmasi tidak adanya efek volatilitas *clustering* yang tersisa.

Uji Goodness-of-Fit Pearson memberikan validasi yang kuat untuk pemilihan distribusi GED. Semua grup yang diuji menunjukkan p-value di atas 0.05, mengindikasikan bahwa distribusi residual terstandarisasi sesuai dengan distribusi GED yang diasumsikan. Hal ini sangat penting karena misspecification dalam distribusi dapat menyebabkan estimasi yang bias dan inferensi yang tidak valid. Uji Sign Bias juga menunjukkan hasil yang baik dengan p-value di atas 0.05, mengindikasikan tidak ada ketidaksimetrisan dalam residual, yang berarti model menangkap efek volatilitas positif dan negatif secara seimbang.

Namun, hasil uji stabilitas Nyblom mengungkapkan adanya keterbatasan dalam model yang perlu mendapat perhatian serius. Statistik gabungan sebesar 9.6587 yang melebihi nilai kritis 5% (1.89) mengindikasikan adanya ketidakstabilan dalam parameter model. Analisis lebih lanjut menunjukkan bahwa ketidakstabilan ini terutama disebabkan oleh parameter  $\omega$  (konstanta GARCH) dengan statistik individual sebesar 2.2398. Hal ini mengindikasikan bahwa parameter volatilitas dasar mengalami perubahan seiring waktu, yang kemungkinan mencerminkan perubahan fundamental dalam kebijakan ekonomi atau *structural breaks* selama periode pengamatan 2023-2025.

Ketidakstabilan parameter  $\omega$  dapat dijelaskan oleh berbagai faktor ekonomi yang terjadi selama periode pengamatan. Periode 2023-2025 merupakan masa yang penuh dengan ketidakpastian ekonomi global, termasuk dampak lanjutan dari pandemi COVID-19, ketegangan geopolitik, perubahan kebijakan moneter global, dan fluktuasi harga komoditas. Faktor-faktor ini dapat menyebabkan perubahan dalam volatilitas dasar nilai tukar, sehingga parameter  $\omega$  tidak konstan sepanjang waktu. Meskipun demikian, ketidakstabilan ini tidak menggugurkan validitas model untuk analisis jangka pendek, namun mengindikasikan perlunya re-estimasi model secara berkala untuk mempertahankan akurasi prediksi.

### 3.3 Analisis Volatilitas Nilai Tukar USD/IDR

Analisis volatilitas nilai tukar USD/IDR berdasarkan model GARCH(1,1) mengungkapkan karakteristik yang sangat menarik dan relevan dengan kondisi perekonomian Indonesia sebagai emerging market. Volatilitas tahunan yang diperoleh dari perhitungan mencapai 5.70%, yang tergolong moderat untuk mata uang emerging market. Tingkat volatilitas ini menunjukkan bahwa Rupiah memiliki karakteristik yang relatif stabil dibandingkan dengan mata uang emerging market lainnya, yang mencerminkan efektivitas kebijakan Bank Indonesia dalam menjaga stabilitas nilai tukar melalui berbagai instrumen kebijakan moneter dan intervensi pasar.

Rentang *return* harian yang berkisar antara -1.29% hingga +1.83% menunjukkan fluktuasi yang signifikan namun masih dalam batas yang dapat dikelola. Fluktuasi ini mencerminkan sensitivitas nilai tukar terhadap berbagai faktor fundamental dan teknikal, termasuk perubahan suku bunga, inflasi, neraca perdagangan, arus modal asing, dan sentimen pasar global. Distribusi return yang mengikuti pola GED dengan fat tails mengindikasikan bahwa meskipun sebagian besar pergerakan berada dalam rentang normal, tetapi ada kemungkinan terjadinya *extreme events* yang perlu diantisipasi dalam manajemen risiko.

Fenomena *volatility clustering* yang berhasil ditangkap oleh model GARCH(1,1) sangat jelas terlihat dalam data nilai tukar USD/IDR. Pola ini menunjukkan bahwa periode dengan volatilitas tinggi cenderung diikuti oleh periode volatilitas tinggi, dan sebaliknya periode volatilitas rendah cenderung diikuti oleh periode volatilitas rendah. Hal ini konsisten dengan teori *behavioral finance* yang menjelaskan bahwa sentimen pasar dan herding behavior dapat menyebabkan volatilitas yang persisten. Dalam konteks pasar valuta asing Indonesia, *volatility clustering* sering terjadi ketika ada ketidakpastian ekonomi global atau domestik yang mempengaruhi kepercayaan investor.

Persistensi volatilitas yang tinggi dengan nilai  $\alpha_1 + \beta_1 = 0.702232$  menunjukkan bahwa shock volatilitas memiliki dampak yang relatif lama. Artinya, ketika terjadi gejolak yang menyebabkan volatilitas tinggi, dampaknya tidak hilang begitu saja dalam satu atau dua periode, tetapi akan terus mempengaruhi volatilitas untuk beberapa periode ke depan. Hal ini memiliki implikasi penting bagi pelaku pasar dan pengambil kebijakan, karena menunjukkan bahwa intervensi untuk menstabilkan volatilitas perlu dilakukan secara konsisten dan berkelanjutan, bukan hanya reaktif sesaat.

Parameter  $\alpha_1 = 0.103523$  yang relatif kecil menunjukkan bahwa pasar valuta asing IDR/USD tidak over-reaktif terhadap berita atau *shock* baru. Hal ini mengindikasikan beberapa hal positif tentang pasar valuta asing Indonesia. Pertama, pasar telah berkembang menjadi relatif matang dan efisien, di mana pelaku pasar tidak mudah terpancing oleh *noise* atau informasi yang tidak substansial. Kedua, efektivitas komunikasi dan intervensi Bank Indonesia dalam mengelola ekspektasi pasar telah cukup baik, sehingga pasar memiliki *anchor* yang jelas dalam pembentukan ekspektasi. Ketiga, struktur pasar yang semakin dalam dengan partisipasi yang beragam membantu mengurangi volatilitas yang berlebihan.

Parameter  $\beta_1 = 0.598709$  yang tinggi menunjukkan adanya *memory effect* yang kuat dalam volatilitas. Hal ini mengindikasikan bahwa volatilitas memiliki komponen yang sangat persistent, yang dapat dijelaskan oleh beberapa faktor. Pertama, adanya structural features dalam pasar valuta asing Indonesia yang menyebabkan volatilitas cenderung bertahan, seperti dominasi investor asing dalam pasar domestik yang dapat menyebabkan *sudden stops* atau *sudden flows*. Kedua, karakteristik ekonomi Indonesia sebagai emerging market yang masih rentan terhadap *external shocks*, sehingga dampak shock cenderung bertahan lama. Ketiga, *policy transmission mechanism* yang memerlukan waktu untuk memberikan dampak stabilisasi.

*Unconditional variance* yang dapat dihitung sebesar  $\frac{\omega}{(1-\alpha_1-\beta_1)} = \frac{-000004}{(1-0.702232)} = 0.0000134$  menunjukkan level volatilitas jangka panjang yang akan dicapai model dalam kondisi *steady state*. Nilai ini mengindikasikan bahwa dalam jangka panjang, tanpa adanya *shock* eksternal yang signifikan, volatilitas nilai tukar akan konvergen ke level yang relatif rendah dan stabil. Hal ini konsisten dengan tujuan kebijakan Bank Indonesia untuk mempertahankan stabilitas nilai tukar dalam jangka panjang.

Analisis temporal volatilitas berdasarkan plot yang dihasilkan mengungkapkan beberapa periode dengan volatilitas tinggi yang dapat diidentifikasi dan dikaitkan dengan events ekonomi tertentu. Periode-periode ini umumnya berkorespondensi dengan ketidakpastian kebijakan ekonomi global, perubahan stance kebijakan moneter baik oleh Bank Indonesia maupun *Federal Reserve*, gejolak geopolitik internasional, atau shock domestik seperti bencana alam atau perubahan kebijakan ekonomi. Identifikasi pola ini sangat penting untuk *early warning system* dan *anticipatory policy making*.

### 3.4 Evaluasi dan Interpretasi Hasil Peramalan

Hasil peramalan yang diperoleh dari model ARMA(2,2)-GARCH(1,1) memberikan insights yang sangat berharga tentang dinamika nilai tukar USD/IDR dalam jangka pendek. Peramalan untuk *return* menunjukkan karakteristik yang sangat konsisten dengan sifat *mean-reverting* yang telah diidentifikasi dalam model. Hasil peramalan 30 langkah ke depan menunjukkan konvergensi yang cepat menuju mean (sekitar nol), yang mengkonfirmasi bahwa return nilai tukar tidak memiliki trend deterministik jangka panjang yang kuat.

Pola konvergensi yang cepat ini memiliki interpretasi ekonomi yang sangat penting. Hal ini menunjukkan bahwa nilai tukar USD/IDR mengikuti karakteristik *random walk* dengan *mean reversion*, di mana deviasi dari nilai rata-rata akan dikoreksi dalam waktu yang relatif singkat. Fenomena ini konsisten dengan teori *efficient market hypothesis*, di mana informasi baru akan segera tercermin dalam harga, dan tidak ada pola sistematis yang dapat dieksplorasi untuk memperoleh *abnormal returns*. Bagi para praktisi dan investor, hal ini mengindikasikan bahwa strategi timing the market dalam jangka pendek akan sangat sulit dan berisiko.

Interval kepercayaan peramalan yang melebar seiring dengan bertambahnya horizon peramalan mencerminkan meningkatnya ketidakpastian seiring dengan jarak prediksi. Hal ini adalah karakteristik normal dalam *time series forecasting*, namun dalam konteks nilai tukar, hal ini memiliki implikasi praktis yang penting. Untuk jangka waktu 1-5 hari ke depan, interval kepercayaan masih relatif sempit, sehingga model dapat memberikan panduan yang berguna untuk manajemen risiko jangka sangat pendek. Namun untuk jangka waktu yang lebih panjang, ketidakpastian menjadi sangat besar sehingga prediksi menjadi kurang *reliable*.

Peramalan volatilitas menunjukkan pola yang sangat menarik dan konsisten dengan teori GARCH. Model memprediksi bahwa volatilitas akan mengalami *mean reversion* menuju *unconditional variance* dengan *decay rate* yang mengikuti pola eksponensial. Hal ini

berarti bahwa setelah periode volatilitas tinggi, volatilitas akan secara bertahap menurun menuju level jangka panjangnya, dengan kecepatan konvergensi yang ditentukan oleh parameter model. Pola ini sangat berguna untuk risk management, karena memberikan gambaran tentang berapa lama periode *adjustment* diperlukan setelah *shock* volatilitas.

Stabilisasi volatilitas pada level jangka panjang sekitar 0.0035 memberikan *benchmark* yang berguna untuk menilai apakah kondisi pasar saat ini normal atau abnormal. Ketika volatilitas *realized* jauh melebihi level ini, dapat dijadikan indikator bahwa pasar sedang mengalami stress atau ketidakpastian yang tinggi, sehingga diperlukan kehati-hatian ekstra dalam pengambilan keputusan investasi atau kebijakan.

Transformasi hasil peramalan dari return ke *closing price* mengungkapkan beberapa keterbatasan yang perlu dipahami dengan baik. Prediksi *price level* menunjukkan stabilitas relatif di sekitar level terakhir, namun ketidakpastian meningkat *drastically* untuk rentang waktu yang lebih panjang. Hal ini disebabkan oleh sifat *compound effect* dalam transformasi logaritmik, di mana ketidakpastian dalam return akan terakumulasi dan menghasilkan ketidakpastian yang lebih besar dalam *price level*.

Keterbatasan ini mengindikasikan bahwa model ARMA-GARCH lebih cocok untuk analisis return dan volatilitas daripada untuk prediksi *price level* jangka panjang. Untuk prediksi *price level*, pendekatan yang menggabungkan analisis fundamental dengan *technical analysis* mungkin lebih *appropriate*, terutama untuk periode prediksi yang lebih panjang. Model yang telah dikembangkan optimal untuk peramalan 1-5 hari ke depan, dan akurasinya akan menurun signifikan untuk periode prediksi yang lebih panjang.

Interpretasi praktis dari hasil peramalan mengindikasikan bahwa model ini sangat berguna untuk aplikasi *daily risk management*, *algorithmic trading strategies*, dan *short-term policy making*. Untuk investor institusional, model dapat digunakan untuk *dynamic hedging strategies* dan *portfolio rebalancing*. Untuk Bank Indonesia, model dapat mendukung decision making dalam intervensi pasar dan komunikasi kebijakan. Namun untuk *strategic long-term decisions*, model perlu dikombinasikan dengan *fundamental analysis* dan *scenario planning*.

### 3.5 Keterbatasan Model

Meskipun model ARMA(2,2)-GARCH(1,1) dengan distribusi GED telah menunjukkan performa yang sangat baik dalam menangkap karakteristik dinamika nilai tukar USD/IDR, terdapat beberapa keterbatasan yang perlu dipahami dan dipertimbangkan dalam aplikasi praktis. Keterbatasan utama yang teridentifikasi adalah ketidakstabilan parameter, khususnya parameter  $\omega$  dalam komponen GARCH, sebagaimana ditunjukkan oleh uji stabilitas Nyblom.

Ketidakstabilan parameter  $\omega$  dengan statistik individual 2.2398 yang melebihi nilai kritis mengindikasikan bahwa volatilitas dasar atau *unconditional variance* mengalami perubahan seiring waktu. Hal ini dapat disebabkan oleh beberapa faktor struktural yang terjadi selama periode pengamatan 2023-2025. Pertama, perubahan dalam struktur ekonomi

Indonesia yang terus berkembang, termasuk deepening financial markets, perubahan komposisi perdagangan internasional, dan evolusi kebijakan ekonomi. Kedua, perubahan dalam *landscape* ekonomi global yang mempengaruhi emerging markets, termasuk perubahan kebijakan moneter negara-negara maju, *trade tensions*, dan *geopolitical uncertainties*.

Implikasi dari ketidakstabilan parameter ini adalah bahwa model memerlukan re-estimasi secara berkala untuk mempertahankan akurasi prediksi. Dalam praktik, hal ini berarti bahwa parameter model yang diestimasi menggunakan data hingga pertengahan 2025 mungkin tidak lagi akurat untuk periode-periode selanjutnya jika terjadi perubahan struktural yang signifikan. Oleh karena itu, implementasi model dalam aplikasi real-time memerlukan monitoring system yang dapat mendeteksi perubahan struktural dan memicu estimasi ulang ketika diperlukan.

Keterbatasan lain yang perlu dipertimbangkan adalah asumsi distribusi GED, meskipun telah menunjukkan fit yang superior dibandingkan distribusi normal atau Student's t. Distribusi GED dengan parameter  $v = 1.076327$  masih merupakan *single-regime distribution* yang mungkin tidak mampu menangkap sepenuhnya *extreme events* atau *crisis periods* yang memiliki karakteristik distribusi yang berbeda. Dalam periode krisis finansial atau gejolak ekonomi, distribusi *return* mungkin mengalami *regime-switching* yang tidak dapat diakomodasi oleh distribusi GED yang statis.

Hal ini mengindikasikan bahwa untuk aplikasi yang melibatkan stress testing atau crisis scenario analysis, model mungkin perlu diperluas dengan pendekatan *regime-switching* atau *threshold models* yang dapat mengakomodasi perubahan distribusi selama periode ekstrem. Pengembangan model *mixture distributions* juga dapat menjadi jalan untuk penelitian lanjutan yang dapat meningkatkan robustness model terhadap perubahan struktural.

Keterbatasan metodologis lain terletak pada asumsi linear dalam komponen ARMA. Meskipun model ARMA(2,2) telah menunjukkan fit yang baik, kemungkinan adanya non-linearities dalam dinamika nilai tukar tidak dapat diabaikan. Pasar valuta asing sering menunjukkan *threshold effects*, *asymmetric responses*, atau *regime-dependent behaviors* yang tidak dapat ditangkap oleh model linear. Pendekatan seperti *threshold autoregressive* (TAR), *smooth transition autoregressive* (STAR), atau *artificial neural networks* mungkin dapat memberikan peningkatan dalam menangkap pola non-linear.

Dari perspektif aplikasi praktis, keterbatasan model juga terletak pada horizon peramalan yang relatif pendek. Model menunjukkan performa terbaik untuk peramalan 1-5 hari ke depan, namun akurasi menurun signifikan untuk jangka waktu yang lebih panjang. Hal ini membatasi *applicability model* untuk *strategic decision making* yang memerlukan *medium to long-term forecasts*. Untuk kebutuhan tersebut, model perlu dikombinasikan dengan analisis fundamental, *structural econometric models*, atau *ensemble forecasting approaches*.

Keterbatasan lain yang perlu dipertimbangkan adalah potential for model *overfitting*, mengingat *complexity* model yang relatif tinggi dengan 8 parameters (4 ARMA + 3 GARCH + 1 distributional parameter). Meskipun semua parameter menunjukkan signifikansi statistik, kemungkinan model terlalu disesuaikan terhadap karakteristik tertentu dari sampel data tidak dapat diabaikan. Validasi di luar sampel dan *cross-validation exercises* akan sangat penting untuk memastikan kemampuan generalisasi model.

Dalam konteks implikasi kebijakan, keterbatasan model juga terletak pada asumsi bahwa hubungan struktural yang ditangkap oleh model akan tetap stabil. Jika terjadi perubahan fundamental dalam *economic policy regime*, struktur pasar keuangan, atau lingkungan ekonomi internasional, model mungkin tidak lagi representatif terhadap proses yang mendasari pembuatan data. Hal ini mengindikasikan perlunya validasi model berkelanjutan dan potential spesifikasi ulang ketika kondisi ekonomi berubah signifikan.

Dari segi teknis, keterbatasan komputasional juga menjadi faktor yang tidak dapat diabaikan dalam penerapan model secara operasional. Proses estimasi model GARCH yang menggunakan *iterative maximum likelihood estimation* membutuhkan daya komputasi yang cukup besar, terutama bila model perlu diperbarui secara rutin untuk keperluan analisis waktu nyata. Dalam implementasi praktis, perlu ada keseimbangan antara tingkat kerumitan model dengan kemampuan komputasi yang tersedia, terutama untuk sistem yang memerlukan pembaruan data secara terus-menerus.

## **BAB IV**

### **KESIMPULAN**

#### **4.1 Kesimpulan**

Berdasarkan hasil analisis terhadap data nilai tukar USD/IDR dari Januari 2023 hingga Juni 2025, dapat disimpulkan beberapa temuan penting yang mendalam mengenai dinamika pasar valuta asing Indonesia dan performa model ARMA(2,2)-GARCH(1,1) dalam memodelkan volatilitas nilai tukar. Kesimpulan utama yang dapat diambil adalah sebagai berikut:

##### **1. Karakteristik Data Nilai Tukar**

Data nilai tukar USD/IDR yang digunakan dalam penelitian ini memperlihatkan adanya tren yang cukup jelas dalam pergerakan harga serta volatilitas yang cukup signifikan. Runtun waktu menunjukkan fluktuasi harian yang cukup besar, namun dengan kecenderungan yang lebih teratur dibandingkan dengan data yang menunjukkan pergerakan acak atau tidak teratur. Terjadi juga fenomena volatilitas yang tinggi yang tercermin dari fluktuasi besar dalam harga, yang mengindikasikan adanya pola volatilitas clustering yang jelas. Penggunaan data dengan pergerakan seperti ini menunjukkan adanya pengaruh dari faktor eksternal seperti kebijakan moneter, krisis internasional, serta spekulasi pasar yang mempengaruhi nilai tukar..

##### **2. Pemilihan Model ARMA(2,2)-GARCH(1,1)**

Model ARMA(2,2)-GARCH(1,1) dengan distribusi Generalized Error Distribution (GED) merupakan model yang paling efektif dalam menangkap karakteristik data nilai tukar USD/IDR. Pendekatan ini berhasil menjelaskan dinamika nilai tukar, termasuk elemen-elemen tren jangka panjang dan volatilitas jangka pendek. Dalam model ini, ARMA(2,2) menangkap pola jangka panjang dalam pergerakan nilai tukar (trend) dengan efek mean-reversion, sementara GARCH(1,1) berperan dalam menangkap volatilitas yang cenderung terklaster. Selain itu, distribusi GED yang digunakan dalam model ini memberikan gambaran yang lebih realistik tentang karakteristik data keuangan yang cenderung memiliki ekor tebal (fat tails) dibandingkan dengan distribusi normal atau Student's t. Dengan demikian, model ini terbukti sangat baik dalam menggambarkan perubahan harga yang tajam dan volatilitas yang tinggi pada data keuangan Indonesia.

##### **3. Model GARCH(1,1) dapat menangkap sifat clustering volatilitas, ekor tebal, dan perilaku mean-reverting dalam fluktuasi nilai tukar, yang sering dijumpai dalam data keuangan.**

##### **4. Peramalan yang dilakukan dengan model ARMA(2,2)-GARCH(1,1) menghasilkan proyeksi yang cukup akurat dalam jangka pendek (1-5 hari ke depan). Hasil peramalan ini menunjukkan konvergensi return yang cepat menuju rata-rata, yang menggambarkan pola mean-reverting yang ada dalam pasar valuta asing Indonesia. Volatilitas yang diprediksi juga menunjukkan pola yang konsisten dengan nilai yang stabil dalam jangka pendek, namun mengalami peningkatan ketidakpastian dalam jangka panjang. Pada peramalan harga (closing price), model ini cenderung menunjukkan stabilitas yang kurang dinamis pada rentang waktu yang lebih panjang,**

yang mengindikasikan bahwa model ini lebih sesuai untuk peramalan jangka pendek dengan horizon prediksi yang terbatas.

5. Meskipun model ARMA(2,2)-GARCH(1,1) dengan distribusi GED memberikan hasil yang baik, terdapat beberapa keterbatasan yang perlu diperhatikan. Salah satunya adalah ketidakstabilan parameter dalam model, khususnya parameter volatilitas dasar (omega) pada komponen GARCH. Uji stabilitas yang dilakukan menggunakan uji Nyblom menunjukkan bahwa parameter volatilitas ini tidak stabil, yang mengindikasikan bahwa volatilitas dasar dapat berubah seiring waktu. Hal ini kemungkinan besar disebabkan oleh perubahan kondisi ekonomi Indonesia dan faktor eksternal yang mempengaruhi pasar selama periode pengamatan 2023-2025. Ketidakstabilan parameter ini memerlukan perhatian khusus karena dapat mempengaruhi akurasi peramalan jangka panjang.

Secara keseluruhan, model ARMA-GARCH yang dikembangkan sangat relevan dan aplikatif untuk analisis risiko serta proyeksi volatilitas dalam konteks pasar valuta asing di Indonesia, khususnya untuk jangka pendek.

## 4.2 Saran

Berdasarkan hasil penelitian, meskipun model ARMA(2,2)-GARCH(1,1) dengan distribusi Generalized Error Distribution (GED) memberikan hasil yang baik, ada beberapa perbaikan yang dapat dilakukan. Pertama, ketidakstabilan parameter volatilitas dasar (omega) menunjukkan perlunya re-estimasi model secara berkala untuk mengakomodasi perubahan dalam kondisi ekonomi. Penggunaan model Integrated GARCH (IGARCH) bisa menjadi alternatif untuk menangani volatilitas yang tidak stabil.

Selain itu, model ini lebih cocok untuk peramalan jangka pendek, sehingga disarankan untuk menggabungkan pendekatan fundamental seperti model struktural ekonomi atau proyeksi makroekonomi untuk meningkatkan akurasi peramalan jangka panjang. Untuk menangani kemungkinan ketidaklinieran dalam data, penggunaan model non-linear seperti Threshold Autoregressive (TAR) atau metode Artificial Neural Networks (ANNs) dapat meningkatkan ketepatan model dalam menangkap pola yang lebih kompleks.

Terakhir, untuk menghindari potensi overfitting, disarankan untuk menggunakan teknik ensemble forecasting seperti bagging atau boosting untuk meningkatkan kestabilan model. Validasi lintas sampel dan pengujian silang juga perlu dilakukan untuk memastikan kemampuan model dalam memprediksi data yang tidak terlihat sebelumnya dan mengurangi risiko kesalahan prediksi.

## **LAMPIRAN**

Link google drive program:

[\*\*PROJECT METODE PERAMALAN - KELOMPOK 7\*\*](#)