


Final Project Model Survival

Regresi Cox-PH



Disusun Oleh:

Kelompok 6

PROGRAM STUDI STATISTIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS INDONESIA

2025

Anggota Kelompok:

No	Nama	NPM	Kontribusi	Tingkat kontribusi
1	Alif Ramdhani Izharulhaq	2306262434	Terlibat aktif dalam diskusi kelompok, melakukan pengecekan asumsi Proportional Hazards (PH), mengerjakan Bagian 3: Uji Asumsi Proportional Hazards (PH)	100%
2	Bryant Farrel Titanius	2306212240	Terlibat aktif dalam diskusi kelompok, melakukan pemodelan Cox-PH, mengerjakan Bagian 4: Pemodelan Menggunakan Model Regresi Cox-PH dan menuliskan Bagian 6: Kesimpulan	100%
3	Franklin Daniel Situmorang	2306201174	Terlibat aktif dalam diskusi kelompok, mengerjakan Latar Belakang, Tujuan Project, dan Bagian 1: Eksplorasi dan Visualisasi Data	100%
4	Ilham Khadafi	2306260952	Terlibat aktif dalam diskusi kelompok dan mengerjakan uji hipotesis. mengerjakan Bagian 5: Pengujian Hipotesis	100%
5	Jesslyn Astrella	2306260965	Terlibat aktif dalam diskusi kelompok dan mengerjakan Bagian 2 : Uji Kaplan-Meier	100%

Latar Belakang

Penyakit kardiovaskular (PKV) merupakan penyebab utama kematian di dunia. Menurut World Health Organization (WHO), setiap tahunnya sekitar 17,9 juta jiwa meninggal akibat penyakit ini, mencakup sekitar 31% dari total kematian global. Salah satu komplikasi serius dari PKV adalah gagal jantung (*heart failure*), sebuah sindrom klinis yang ditandai oleh ketidakmampuan jantung dalam memompa darah secara efektif ke seluruh tubuh.

Gagal jantung sendiri bukanlah penyakit tunggal, melainkan manifestasi akhir dari berbagai gangguan struktural atau fungsional jantung. Gejalanya meliputi sesak napas, kelelahan ekstrem, dan edema (pembengkakan). Ketika jantung gagal berfungsi dengan optimal, organ-organ tubuh lain pun dapat terdampak secara sistemik dan progresif, hingga berujung pada kematian jika tidak ditangani dengan tepat.

Penyakit jantung bukan hanya isu kesehatan global, tetapi juga masalah kesehatan serius di Indonesia. Peningkatan tren ini menjadi alarm penting bagi sistem kesehatan untuk merespons dengan strategi pencegahan dan deteksi dini yang lebih baik. Sebagian besar penyebab penyakit jantung dapat dicegah. Faktor-faktor risiko seperti merokok, pola makan tidak sehat, obesitas, kurang aktivitas fisik, serta konsumsi alkohol berlebihan merupakan penyumbang terbesar. Pencegahan melalui edukasi gaya hidup sehat dan intervensi dini pada populasi berisiko tinggi sangat diperlukan.

Gagal jantung dipengaruhi oleh beragam faktor. Berdasarkan data yang digunakan dalam studi ini, terdapat 12 variabel klinis penting yang dapat mempengaruhi risiko kematian akibat gagal jantung. Untuk memahami perjalanan penyakit dan waktu kematian akibat gagal jantung, diperlukan pendekatan statistik yang tepat. Model survival menjadi metode utama yang digunakan dalam menganalisis data waktu-kejadian (time-to-event), di mana peristiwa yang dikaji adalah kematian. Dua pendekatan populer dalam analisis survival: Kaplan-Meier Estimator – menggambarkan fungsi kelangsungan hidup secara non-parametrik; dan Cox Proportional Hazards Model (Cox-PH) – menganalisis pengaruh faktor risiko terhadap waktu bertahan hidup secara semi-parametrik.

Tujuan Project

Project ini bertujuan untuk:

1. Menganalisis pengaruh variabel-variabel klinis terhadap peluang hidup pasien gagal jantung, dengan menelusuri hubungan antara karakteristik medis pasien terhadap waktu bertahan hidup.
2. Mengidentifikasi variabel klinis yang berpengaruh secara signifikan terhadap risiko kematian pasien gagal jantung, sehingga dapat memberikan wawasan klinis dan mendukung pengambilan keputusan medis berbasis data.
3. Menggambarkan fungsi kelangsungan hidup pasien gagal jantung menggunakan Kaplan-Meier Estimator, sebagai pendekatan non-parametrik untuk memperlihatkan perbedaan survival antara kelompok pasien.
4. Menerapkan dan mengevaluasi model regresi Cox Proportional Hazards (Cox-PH) dalam menganalisis data time-to-event pasien gagal jantung untuk mengetahui pola kelangsungan hidup berdasarkan faktor risiko yang ada.

1. Eksplorasi dan Visualisasi Data

Informasi Data : Data yang digunakan dalam penelitian ini diambil dari [Kaggle – Heart Failure Clinical Records Dataset](#). Dataset ini berisi catatan medis dari 299 pasien penderita gagal jantung yang mengalami disfungsi sistolik ventrikel kiri, suatu kondisi ketika ventrikel kiri jantung tidak dapat memompa darah secara efisien ke seluruh tubuh. Data ini sangat relevan untuk studi survival analysis karena mencakup waktu tindak lanjut dan status kematian (*death event*) selama periode observasi, serta sejumlah variabel klinis yang berpotensi memengaruhi kelangsungan hidup pasien.

Variabel Klinis dalam Dataset	
Nama Variabel	Deskripsi
age	Usia pasien (dalam tahun)
anaemia	Apakah pasien menderita anemia (0 = tidak, 1 = ya)
creatinine_phosphokinase	Tingkat enzim CPK dalam darah (mcg/L), yang meningkat jika terjadi kerusakan otot jantung
diabetes	Apakah pasien menderita diabetes (0 = tidak, 1 = ya)
ejection_fraction	Persentase darah yang dikeluarkan oleh ventrikel kiri setiap kali jantung berkontraksi
high_blood_pressure	Apakah pasien memiliki tekanan darah tinggi (0 = tidak, 1 = ya)
serum_creatinine	Kadar kreatinin dalam darah, indikator fungsi ginjal
serum_sodium	Kadar natrium dalam darah, berpengaruh pada stabilitas sel dan tekanan darah
platelets	Jumlah trombosit dalam darah, berperan penting dalam pembekuan darah
sex	Jenis kelamin pasien (0 = wanita, 1 = pria)
smoking	Apakah pasien seorang perokok (0 = tidak, 1 = ya)
time	Durasi follow-up dalam hari sejak diagnosis atau awal pengobatan
DEATH_EVENT	Status kematian selama periode follow-up (0 = bertahan hidup, 1 = meninggal)

Preprocessing Data : Tahapan *preprocessing* data pada penelitian ini dimulai dengan mengimpor berbagai pustaka penting seperti `pandas`, `numpy`, `matplotlib`, `seaborn`, dan `plotly` untuk

keperluan analisis dan visualisasi data. Dataset yang berisi 299 catatan medis pasien gagal jantung kemudian dimuat dari direktori Google Drive menggunakan `pandas.read_csv()`. Untuk mendapatkan gambaran awal, lima baris pertama dari data ditampilkan, disusul dengan pemeriksaan dimensi data yang mengonfirmasi adanya 299 baris dan 13 kolom. Pemeriksaan tipe data dilakukan untuk memastikan bahwa seluruh kolom memiliki tipe data numerik (baik `int64` maupun `float64`), sehingga cocok untuk keperluan analisis statistik dan visualisasi. Selanjutnya, dilakukan verifikasi terhadap kelengkapan data dengan metode `df.isnull().sum()`, dan hasilnya menunjukkan bahwa tidak ada nilai yang hilang pada seluruh variabel, sehingga tidak diperlukan imputasi atau penghapusan data.


Langkah berikutnya adalah eksplorasi statistik deskriptif melalui `df.describe()`, yang memberikan ringkasan statistik seperti nilai minimum, maksimum, rata-rata, serta kuartil untuk masing-masing variabel. Kemudian, hubungan antar variabel dianalisis melalui *pairplot* dari *seaborn*.



Gambar 1.1 Pairplot berdasarkan DEATH_EVENT


Visualisasi pairplot ini menyajikan hubungan antar variabel numerik dan biner dalam dataset pasien penyakit jantung, yang dikelompokkan berdasarkan status kematian (variabel DEATH_EVENT). Setiap titik dalam scatterplot mewakili individu, dengan warna hijau untuk pasien yang bertahan hidup dan warna merah untuk pasien yang meninggal. Dari plot distribusi diagonal, terlihat bahwa pasien yang meninggal cenderung memiliki nilai ejection fraction dan serum sodium yang lebih rendah, serta kadar serum creatinine yang lebih tinggi, dibandingkan pasien yang hidup. Hal ini mengindikasikan bahwa ketiga variabel tersebut mungkin berperan penting dalam menentukan risiko kematian. Selain itu, pada scatterplot antar variabel, terlihat kecenderungan klaster yang berbeda antara kelompok hidup dan meninggal pada kombinasi seperti `ejection_fraction` vs `serum_creatinine` dan `serum_sodium` vs `time`. Variabel `time`, yang merepresentasikan waktu pengamatan, tampak berdistribusi lebih panjang pada pasien yang bertahan hidup, menandakan bahwa mereka hidup lebih lama selama masa studi. Sementara itu, variabel biner seperti `diabetes`, `high_blood_pressure`, dan `smoking` tampaknya tidak menunjukkan pola yang sangat jelas dalam membedakan antara kedua kelompok, meskipun tetap layak untuk diuji lebih lanjut secara statistik. Secara keseluruhan, visualisasi ini membantu mengidentifikasi variabel-variabel yang berpotensi penting dalam memengaruhi status kematian dan dapat menjadi acuan untuk analisis lanjutan.

Setelah itu, distribusi kelas target DEATH_EVENT dianalisis dengan menghitung frekuensi dan persentasenya, yang menunjukkan bahwa sekitar 32% pasien dalam dataset mengalami kematian selama periode tindak lanjut.



Gambar 1.2 Bar Chart DEATH_EVENT


Untuk menilai pengaruh variabel terhadap status kematian secara visual, dilakukan visualisasi *boxplot* untuk setiap fitur numerik berdasarkan DEATH_EVENT, yang membantu mendeteksi keberadaan outlier dan melihat perbedaan distribusi nilai antar kelompok hidup dan meninggal.



Gambar 1.3 Boxplot berdasarkan DEATH_EVENT

Visualisasi boxplot berdasarkan variabel DEATH_EVENT ini memberikan gambaran perbedaan distribusi antara pasien yang meninggal (label 1) dan yang bertahan hidup (label 0) untuk setiap variabel. Terlihat bahwa pasien yang meninggal cenderung memiliki usia (age) yang sedikit lebih tua, nilai ejection fraction yang lebih rendah, serta kadar serum creatinine yang lebih tinggi—faktor-faktor yang dapat mengindikasikan kondisi jantung dan ginjal yang memburuk. Selain itu, nilai serum sodium pada kelompok meninggal tampak sedikit lebih rendah dibandingkan kelompok yang hidup, yang menunjukkan kemungkinan adanya gangguan elektrolit. Nilai time, yang merepresentasikan durasi pengamatan atau tindak lanjut, secara mencolok lebih pendek pada pasien yang meninggal, memperkuat kesan bahwa mereka mengalami kejadian kematian lebih awal. Sebaliknya, variabel-variabel biner seperti anaemia, diabetes, high_blood_pressure, sex, dan smoking menunjukkan distribusi yang hampir simetris antara kedua kelompok, mengindikasikan bahwa variabel-variabel ini mungkin tidak terlalu berpengaruh secara langsung terhadap kejadian kematian dalam populasi ini. Variabel creatinine_phosphokinase dan platelets juga tampak memiliki sebaran yang lebar dengan keberadaan outlier, namun median antar kelompok tidak terlalu berbeda secara mencolok. Secara keseluruhan, boxplot ini menyoroti beberapa variabel klinis yang potensial untuk digunakan dalam prediksi risiko kematian, seperti ejection_fraction, serum_creatinine, dan time, yang menunjukkan perbedaan distribusi paling jelas antara pasien yang meninggal dan yang bertahan hidup.

Terakhir, korelasi antar variabel numerik dievaluasi dengan *heatmap* menggunakan metode `df.corr()`.




Gambar 1.4 Heatmap Korelasi Antar Variabel

Heatmap korelasi ini menggambarkan kekuatan dan arah hubungan linier antara pasangan variabel dalam dataset, termasuk kaitannya dengan DEATH_EVENT. Korelasi tertinggi terhadap variabel DEATH_EVENT ditunjukkan oleh variabel `time` dengan nilai korelasi negatif yang kuat sekitar -0.53, menandakan bahwa semakin pendek waktu pengamatan (yaitu semakin cepat pasien meninggal), semakin besar kemungkinan terjadi peristiwa kematian. Selain itu, `ejection_fraction` dan `serum_sodium` juga menunjukkan korelasi negatif dengan DEATH_EVENT, masing-masing sebesar -0.27 dan -0.20, yang mencerminkan bahwa semakin rendah nilai `ejection fraction` dan kadar sodium, semakin besar kemungkinan pasien mengalami kematian. Sebaliknya, variabel `serum_creatinine` dan `age` memiliki korelasi positif masing-masing sebesar 0.29 dan 0.25, mengindikasikan bahwa pasien dengan kadar creatinine dan usia yang lebih tinggi cenderung memiliki risiko kematian yang lebih besar. Di sisi lain, sebagian besar variabel lainnya seperti `anaemia`, `diabetes`, `high_blood_pressure`, `sex`, `smoking`, dan `platelets` memiliki korelasi yang sangat rendah (mendekati nol) terhadap DEATH_EVENT, menunjukkan bahwa hubungan linier langsung antara variabel-variabel tersebut dengan status kematian tidak signifikan secara statistik. Pola-pola ini mendukung temuan sebelumnya dari boxplot dan pairplot, dan memperkuat bahwa variabel-variabel

seperti `time`, `ejection_fraction`, `serum_creatinine`, `serum_sodium`, dan `age` berpotensi menjadi prediktor penting dalam memodelkan risiko kematian pada pasien.


Eksplorasi Data : Analisis lanjutan terhadap faktor-faktor biner dalam dataset gagal jantung—yaitu anemia, diabetes, tekanan darah tinggi (hipertensi), dan kebiasaan merokok—dilakukan secara visual melalui *donut chart*. Visualisasi ini membantu memperjelas distribusi proporsi tiap kategori dan kaitannya dengan status kematian pasien. Setiap plot disusun tidak hanya berdasarkan kondisi kesehatan semata, tetapi juga mempertimbangkan jenis kelamin dan kombinasi antara semua variabel tersebut untuk mendalami dimensi demografis yang mungkin relevan.

Analisis Anemia




Gambar 1.5 Donut Chart Anemia dan Status Kematian

Grafik ini menunjukkan distribusi pasien gagal jantung berdasarkan status anemia dan status hidup atau meninggal. Sebagian besar pasien berada dalam kategori “Tidak Anemia - Hidup” (40,1%), diikuti oleh “Anemia - Hidup” (27,8%), yang menunjukkan bahwa meskipun anemia dapat menjadi faktor risiko, cukup banyak pasien anemia yang tetap bertahan hidup. Sementara itu, persentase pasien yang meninggal relatif seimbang antara yang menderita anemia (15,4%) dan yang tidak (16,7%), mengindikasikan bahwa anemia memang dapat meningkatkan risiko kematian, tetapi bukan satu-satunya faktor penentu. Secara keseluruhan, grafik ini menyiratkan bahwa tidak mengalami anemia berkorelasi dengan peluang hidup yang lebih tinggi, meskipun anemia tidak sepenuhnya menentukan kematian pasien.



Gambar 1.6 Donut Chart Jenis Kelamin dan Kondisi Anemia

Grafik ini menyajikan distribusi pasien berdasarkan jenis kelamin dan kondisi anemia. Terlihat bahwa kelompok terbesar adalah laki-laki tanpa anemia, yang mencakup 39,1% dari total pasien, disusul oleh laki-laki dengan anemia sebesar 25,8%. Sementara itu, perempuan memiliki proporsi yang lebih seimbang antara yang mengalami anemia (17,4%) dan yang tidak (17,7%). Data ini menunjukkan bahwa laki-laki lebih banyak ditemukan dalam populasi pasien, baik yang menderita maupun tidak menderita anemia. Meskipun anemia cukup merata pada pasien perempuan, prevalensinya tetap lebih rendah dibandingkan laki-laki, baik dalam kondisi anemia maupun tidak anemia. Hal ini dapat mencerminkan kemungkinan perbedaan karakteristik biologis atau pola deteksi dini yang berbeda antar jenis kelamin.




Gambar 1.7 Donut Chart Jenis Kelamin, Anemia, dan Status Kematian

Grafik ini menggambarkan distribusi pasien berdasarkan kombinasi jenis kelamin, kondisi anemia, dan status kematian. Terlihat bahwa kelompok terbesar adalah laki-laki yang tidak mengalami anemia dan masih hidup, mencakup 27,1% dari keseluruhan populasi pasien. Kelompok laki-laki dengan anemia yang masih hidup juga cukup signifikan dengan persentase 17,1%, diikuti oleh perempuan tanpa anemia yang masih hidup dengan persentase 13,0%.


anemia yang masih hidup (13,0%) serta laki-laki tanpa anemia yang telah meninggal (12,0%). Sementara itu, perempuan dengan anemia yang masih hidup berada pada angka 10,7%, sedikit lebih tinggi dibandingkan laki-laki dengan anemia yang telah meninggal (8,7%). Kelompok dengan proporsi terkecil adalah perempuan tanpa anemia yang telah meninggal (4,7%) dan perempuan dengan anemia yang telah meninggal (6,7%). Secara umum, data ini menunjukkan bahwa sebagian besar pasien yang bertahan hidup adalah laki-laki tanpa anemia, sementara angka kematian relatif lebih rendah pada perempuan, baik yang memiliki anemia maupun tidak. Distribusi ini dapat merefleksikan pengaruh gabungan antara jenis kelamin dan kondisi anemia terhadap kemungkinan bertahan hidup pasien.

Analisis Diabetes




Gambar 1.8 Donut Chart Diabetes dan Status Kematian

Grafik ini menunjukkan hubungan antara status diabetes dan status kematian pada pasien. Terlihat bahwa proporsi tertinggi berasal dari kelompok pasien yang tidak menderita diabetes dan masih hidup, yakni sebesar 39,5%. Diikuti oleh kelompok pasien dengan diabetes yang masih hidup sebesar 28,4%, menunjukkan bahwa sebagian besar penderita diabetes masih memiliki kemungkinan bertahan hidup yang cukup tinggi. Sementara itu, kelompok pasien yang tidak memiliki diabetes namun meninggal dunia mencakup 18,7% dari keseluruhan populasi, sedikit lebih tinggi dibandingkan kelompok pasien dengan diabetes yang meninggal, yaitu sebesar 13,4%. Dari data ini dapat disimpulkan bahwa keberadaan diabetes memang memiliki kaitan dengan status kematian, namun bukan satu-satunya faktor penentu, karena kematian juga cukup tinggi terjadi pada pasien non-diabetes. Secara keseluruhan, pasien non-diabetes cenderung memiliki tingkat kelangsungan hidup yang lebih tinggi, tetapi proporsi kematian tetap ada di kedua kelompok, baik dengan maupun tanpa diabetes.



Gambar 1.9 Donut Chart Jenis Kelamin dan Kondisi Diabetes

Grafik ini menyajikan distribusi kondisi diabetes berdasarkan jenis kelamin. Mayoritas individu dalam data adalah laki-laki tanpa diabetes, yang mencakup 41,5% dari total, menunjukkan bahwa kelompok ini merupakan bagian terbesar dari populasi. Selanjutnya, laki-laki dengan diabetes menyumbang 23,4%, yang berarti sekitar seperempat laki-laki dalam data menderita diabetes. Pada kelompok perempuan, proporsi penderita diabetes dan yang tidak diabetes relatif seimbang, yaitu masing-masing sebesar 18,4% dan 16,7%. Hal ini menunjukkan bahwa pada perempuan, distribusi antara yang menderita diabetes dan yang tidak cukup merata, meskipun tetap lebih rendah dibandingkan laki-laki. Secara keseluruhan, prevalensi diabetes terlihat lebih tinggi pada laki-laki dibandingkan perempuan, baik dalam kelompok penderita maupun non-penderita, yang bisa mengindikasikan adanya pengaruh faktor gender dalam kerentanan terhadap diabetes atau dalam aspek deteksi dan pelaporan kasus.




Gambar 1.10 Donut Chart Jenis Kelamin, Diabetes, dan Status Kematian

Grafik ini menunjukkan hubungan antara jenis kelamin, status diabetes, dan status kematian. Terlihat bahwa kelompok dengan proporsi terbesar adalah laki-laki tanpa diabetes yang masih hidup, yakni


sebanyak 27,4%, disusul oleh laki-laki dengan diabetes yang hidup sebesar 16,7%, dan laki-laki tanpa diabetes yang meninggal sebesar 14%. Sementara itu, perempuan tanpa diabetes yang hidup menyumbang 12% dari total, diikuti oleh perempuan dengan diabetes yang hidup sebesar 11,7%. Angka kematian pada kelompok perempuan dengan diabetes dan laki-laki dengan diabetes sama-sama sebesar 6,7%, sedangkan perempuan tanpa diabetes yang meninggal mencakup 4,7% dari populasi. Hasil ini mengindikasikan bahwa laki-laki memiliki proporsi yang lebih besar baik dalam kondisi hidup maupun meninggal, terlepas dari status diabetesnya. Selain itu, terlihat bahwa individu yang hidup, baik laki-laki maupun perempuan, cenderung lebih banyak berasal dari kelompok tanpa diabetes, meskipun proporsi penderita diabetes yang masih hidup juga cukup signifikan. Secara keseluruhan, grafik ini menegaskan bahwa diabetes dan jenis kelamin berperan dalam pola kelangsungan hidup, dengan laki-laki mendominasi pada hampir semua kombinasi kondisi.

Analisis Tekanan Darah Tinggi (Hipertensi)




Gambar 1.11 Donut Chart Tekanan Darah dan Status Kematian

Grafik ini menggambarkan hubungan antara kondisi tekanan darah (hipertensi atau tidak) dengan status kematian individu. Dari hasil visualisasi, terlihat bahwa proporsi terbesar berasal dari kelompok yang tidak mengalami hipertensi dan masih hidup, yakni sebesar 45,8%. Ini menunjukkan bahwa hampir setengah dari populasi berada dalam kondisi tekanan darah normal dan tetap hidup. Sementara itu, kelompok penderita hipertensi yang hidup menyumbang 22,1%, menunjukkan bahwa sebagian individu dengan tekanan darah tinggi masih dapat bertahan hidup. Kelompok tanpa hipertensi namun meninggal mencakup 19,1% dari total populasi, sedangkan kelompok penderita hipertensi yang meninggal merupakan proporsi terkecil, yaitu hanya 13,0%. Secara keseluruhan, grafik ini mengindikasikan bahwa individu tanpa hipertensi cenderung memiliki peluang hidup yang lebih besar, namun kematian juga terjadi pada mereka yang tidak mengalami hipertensi, sehingga faktor-faktor lain di luar tekanan darah kemungkinan turut berperan dalam menentukan status kematian seseorang.



Gambar 1.12 Donut Chart Jenis Kelamin dan Kondisi Tekanan Darah

Grafik ini menggambarkan distribusi kondisi tekanan darah berdasarkan jenis kelamin. Terlihat bahwa proporsi terbesar adalah laki-laki yang tidak mengalami hipertensi, yaitu sebesar 44,5%, menunjukkan bahwa hampir setengah dari populasi yang diamati adalah pria dengan tekanan darah normal. Selanjutnya, laki-laki yang mengalami hipertensi dan perempuan yang tidak hipertensi memiliki proporsi yang sama, masing-masing sebesar 20,4%. Ini menunjukkan bahwa hipertensi pada laki-laki dan kondisi tekanan darah normal pada perempuan memiliki jumlah yang seimbang dalam populasi. Sementara itu, kelompok dengan proporsi terkecil adalah perempuan yang mengalami hipertensi, yaitu sebesar 14,7%. Secara keseluruhan, visualisasi ini menampilkan bahwa laki-laki cenderung memiliki proporsi yang lebih besar dibanding perempuan dalam hal kondisi tekanan darah, baik dalam kategori hipertensi maupun tidak hipertensi, dengan dominasi paling besar pada laki-laki yang tidak hipertensi.




Gambar 1.13 Donut Chart Jenis Kelamin, Tekanan Darah, dan Status Kematian

Grafik ini menyajikan distribusi gabungan antara jenis kelamin, kondisi tekanan darah, dan status kematian. Proporsi terbesar berasal dari kelompok laki-laki yang tidak mengalami hipertensi dan masih hidup, yaitu sebesar 31,1%. Kelompok berikutnya yang memiliki proporsi cukup besar adalah perempuan tidak hipertensi yang hidup (14,7%), diikuti oleh laki-laki tidak hipertensi meninggal


(13,4%) dan laki-laki hipertensi hidup (13,0%). Hal ini mengindikasikan bahwa meskipun tidak hipertensi, beberapa individu laki-laki tetap mengalami kematian, yang mungkin dipengaruhi oleh faktor risiko lain. Proporsi perempuan hipertensi yang hidup sebesar 9,0%, sementara laki-laki hipertensi yang meninggal mencapai 7,4%, menunjukkan adanya risiko kematian yang nyata pada penderita hipertensi, khususnya pada laki-laki. Dua kategori dengan proporsi terendah, masing-masing sebesar 5,7%, adalah perempuan tidak hipertensi meninggal dan perempuan hipertensi meninggal, yang bisa mencerminkan ketahanan hidup yang relatif lebih baik pada perempuan atau ukuran sampel yang lebih kecil dalam kelompok tersebut. Secara keseluruhan, grafik ini menggambarkan bahwa laki-laki tanpa hipertensi memiliki kondisi kelangsungan hidup terbaik, sedangkan kelompok hipertensi, terutama laki-laki, menunjukkan kecenderungan peningkatan risiko kematian.

Analisis Kebiasaan Merokok




Gambar 1.14 Donut Chart Merokok dan Status Kematian

Grafik ini menggambarkan hubungan antara kebiasaan merokok dengan status kematian individu. Dari hasil visualisasi, terlihat bahwa proporsi terbesar berasal dari kelompok yang tidak merokok dan masih hidup, yakni sebesar 45,8%. Hal ini menunjukkan bahwa hampir setengah dari populasi dalam data merupakan individu yang tidak memiliki kebiasaan merokok dan tetap bertahan hidup. Selanjutnya, terdapat dua kelompok dengan proporsi yang sama besar, masing-masing sebesar 22,1%, yaitu kelompok perokok yang masih hidup dan kelompok bukan perokok yang telah meninggal. Sementara itu, kelompok dengan proporsi terkecil adalah perokok yang meninggal, yaitu sebesar 10,0%. Secara keseluruhan, grafik ini mengindikasikan bahwa individu yang tidak merokok cenderung memiliki peluang hidup yang lebih besar, namun kematian juga terjadi pada kelompok yang tidak merokok maupun kelompok yang merokok, sehingga kemungkinan terdapat faktor-faktor lain di luar kebiasaan merokok yang turut memengaruhi status kematian seseorang.



Gambar 1.15 Donut Chart Jenis Kelamin dan Kebiasaan Merokok

Grafik ini menggambarkan hubungan antara jenis kelamin dengan kebiasaan merokok pada populasi yang diamati. Dari hasil visualisasi, terlihat bahwa kelompok terbesar adalah laki-laki yang tidak merokok, dengan persentase sebesar 34,1%, disusul oleh kelompok perempuan yang tidak merokok sebesar 33,8%. Ini menunjukkan bahwa sebagian besar populasi tidak memiliki kebiasaan merokok, baik laki-laki maupun perempuan. Kelompok laki-laki yang merokok menempati posisi ketiga dengan proporsi sebesar 30,8%, yang mencerminkan bahwa sebagian besar perokok berasal dari kalangan laki-laki. Sementara itu, kelompok dengan proporsi terkecil adalah perempuan yang merokok, yaitu hanya sebesar 1,3%, mengindikasikan bahwa kebiasaan merokok sangat jarang ditemukan di kalangan perempuan. Secara keseluruhan, grafik ini menunjukkan bahwa kebiasaan merokok lebih banyak terjadi pada laki-laki dibandingkan perempuan, dan mayoritas individu dalam populasi lebih cenderung tidak merokok, terlepas dari jenis kelaminnya.



Gambar 1.16 Donut Chart Jenis Kelamin, Merokok, dan Status Kematian

Grafik ini menggambarkan hubungan antara jenis kelamin, kebiasaan merokok, dan status kematian pada populasi yang diamati. Terlihat bahwa kelompok dengan proporsi terbesar adalah perempuan yang tidak merokok dan masih hidup, yaitu sebesar 23,4%, diikuti oleh laki-laki yang tidak merokok dan hidup sebesar 22,4%, serta laki-laki yang merokok dan hidup sebesar 21,7%. Ketiga kelompok ini menunjukkan bahwa mayoritas individu dalam populasi masih hidup, baik yang merokok maupun tidak, dengan proporsi tertinggi berasal dari kelompok non-perokok. Sementara itu, proporsi kematian tertinggi berasal dari laki-laki yang tidak merokok (11,7%), disusul oleh perempuan yang tidak merokok (10,4%), dan laki-laki yang merokok (9,0%). Di sisi lain, kelompok dengan proporsi terkecil adalah perempuan yang merokok, baik yang hidup maupun yang meninggal, masing-masing hanya sebesar 0,3% dan 1,0%, yang menunjukkan bahwa perempuan perokok merupakan minoritas dalam data ini. Secara keseluruhan, grafik ini mengindikasikan bahwa status hidup lebih banyak didominasi oleh kelompok non-perokok, baik laki-laki maupun perempuan, dan bahwa kebiasaan merokok tampaknya lebih umum terjadi pada laki-laki, sementara jumlah perempuan perokok sangat sedikit sehingga pengaruhnya terhadap status kematian dalam populasi ini tampak minimal.

2. Uji Kaplan-Meier

Analisis Kaplan-Meier digunakan untuk memperkirakan probabilitas kelangsungan hidup pada data survival. Dalam penelitian ini, kami menggunakan beberapa variabel terkait dengan gagal jantung yang terdapat di dataset untuk diuji menggunakan analisis kaplan-meier dengan fokus pada waktu kelangsungan hidup hingga kematian yang tercatat dalam dataset. Berikut adalah hasil uji yang kami dapatkan,


1. Gagal jantung berdasarkan Status Perokok dan Bukan Perokok

```
HASIL UJI LOG-RANK:  
> print(log_rank_test)  
Call:  
survdiff(formula = surv_object ~ smoking_status, data = data)  
  
              N Observed Expected (O-E)^2/E  
smoking_status=Bukan Perokok 203      66    65.8    0.00064  
smoking_status=Perokok      96      30    30.2    0.00139  
              (O-E)^2/V  
smoking_status=Bukan Perokok    0.00204  
smoking_status=Perokok          0.00204  
  
Chisq= 0 on 1 degrees of freedom, p= 1
```

```
> # Hitung p-value  
> p_value <- 1 - pchisq(log_rank_test$chisq, df = 1)  
> cat("P-value uji Log-rank:", round(p_value, 4), "\n")  
P-value uji Log-rank: 0.964  
> if(p_value < 0.05) {  
+   cat("Kesimpulan: Terdapat perbedaan signifikan dalam survival antara peroko  
k dan bukan perokok (p < 0.05)\n\n")  
+ } else {  
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan dalam survival antara  
perokok dan bukan perokok (p >= 0.05)\n\n")  
+ }  
Kesimpulan: Tidak terdapat perbedaan signifikan dalam survival antara perokok d  
an bukan perokok (p >= 0.05)
```

Gambar 2.1 Hasil Uji Log-Rank Status Perokok

Hasil uji log rank menunjukkan p-value sebesar 0.964 yang lebih besar dari 0.05 yang menunjukkan bahwa tidak ada perbedaan signifikan antara kelangsungan hidup perokok dan bukan perokok.



Gambar 2.2 Hasil Kurva Kaplan-Meier Perokok vs Bukan Perokok

Berdasarkan kurva kaplan-meier di atas, dapat dilihat bahwa tidak ada perbedaan yang signifikan dalam kelangsungan hidup antara kelompok perokok dan bukan perokok. Meskipun kelompok bukan perokok tampak memiliki sedikit keunggulan dalam kelangsungan hidup pada awalnya, perbedaan antara kedua kelompok semakin kecil seiring berjalannya waktu. Pada grafik ini juga telah dicantumkan "Number at Risk" yang menunjukkan bahwa meskipun ada penurunan jumlah individu dalam kedua kelompok, keduanya menunjukkan pola kelangsungan hidup yang serupa sepanjang waktu.

2. Gagal Jantung berdasarkan Kelompok Usia

```
Hasil Uji Log-rank:
> print(log_rank_age)
Call:
survdiff(formula = surv_object ~ age_group_status, data = data)


              N Observed Expected (O-E)^2/E
age_group_status=Usia <65 tahun 184      46      62.7      4.44
age_group_status=Usia ≥65 tahun 115      50      33.3      8.36
              (O-E)^2/V
age_group_status=Usia <65 tahun      12.9
age_group_status=Usia ≥65 tahun      12.9

Chisq= 12.9 on 1 degrees of freedom, p= 3e-04
```

```
> cat("P-value:", round(p_age, 4), "\n")
P-value: 3e-04
> if(p_age < 0.05) {
+   cat("Kesimpulan: Terdapat perbedaan signifikan berdasarkan kelompok usia (p
< 0.05)\n")
+ } else {
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan kelompok u
sia (p >= 0.05)\n")
+ }
Kesimpulan: Terdapat perbedaan signifikan berdasarkan kelompok usia (p < 0.05)
```

Gambar 2.3 Hasil Uji Log-Rank Kelompok Usia

Hasil uji log rank menunjukkan p-value yang sangat kecil < 0.05 yang mengindikasikan bahwa terdapat perbedaan signifikan dalam kelangsungan hidup antara kelompok usia < 65 tahun dan ≥ 65 tahun.



Gambar 2.4 Hasil Kurva Kaplan-Meier Kelompok Usia

Pada grafik ini, terlihat bahwa kelompok usia < 65 tahun memiliki kelangsungan hidup yang lebih baik dibandingkan dengan kelompok usia ≥ 65 tahun. Disini terlihat bahwa kelompok usia < 65 tahun menunjukkan probabilitas kelangsungan hidup yang lebih tinggi sepanjang waktu. P-value nya juga sangat kecil yang mengindikasikan terdapat perbedaan yang signifikan. “Number at Risk” menunjukkan angka ini berkurang seiring berjalannya waktu dengan masing-masing kelompok menunjukkan jumlah pasien yang berisiko lebih sedikit saat mendekati akhir pengamatan.

3. Gagal Jantung berdasarkan Fraksi Ejeksi

```
Hasil Uji Log-rank:
> print(log_rank_ef)
Call:
survdif(formula = surv_object ~ ef_group_status, data = data)
```


	N	Observed	Expected
ef_group_status=EF <40% (Reduced)	182	73	58.3
ef_group_status=EF ≥40% (Preserved/Mid-range)	117	23	37.7
		(O-E) ² /E	(O-E) ² /V
ef_group_status=EF <40% (Reduced)		3.69	9.47
ef_group_status=EF ≥40% (Preserved/Mid-range)		5.72	9.47

Chisq= 9.5 on 1 degrees of freedom, p= 0.002

```
> cat("P-value:", round(p_ef, 4), "\n")
P-value: 0.0021
> if(p_ef < 0.05) {
+   cat("Kesimpulan: Terdapat perbedaan signifikan berdasarkan fraksi ejeksi (p
< 0.05)\n")
+ } else {
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan fraksi eje
ksi (p >= 0.05)\n")
+ }
Kesimpulan: Terdapat perbedaan signifikan berdasarkan fraksi ejeksi (p < 0.05)
> cat("\n")
```

Gambar 2.5 Hasil Uji Log-Rank Fraksi Ejeksi

Hasil uji log rank menunjukkan p-value yang lebih kecil dari 0.05 yang mengindikasikan bahwa terdapat perbedaan signifikan dalam kelangsungan hidup antara pasien dengan fraksi ejeksi < 40% dan $\geq$ 40%.



Gambar 2.6 Hasil Kurva Kaplan-Meier Fraksi Ejeksi

Pada grafik ini, terlihat bahwa kelompok EF <40% menunjukkan penurunan yang lebih cepat dalam probabilitas kelangsungan hidup dibandingkan dengan kelompok EF $\geq$ 40% yang menunjukkan kelangsungan hidup yang lebih tinggi dan lebih stabil. P-value nya juga kurang dari 0.05 yang mengindikasikan terdapat perbedaan signifikan. “Number at Risk” menunjukkan jumlah yang berkurang seiring berjalannya waktu dengan kelompok EF <40% menunjukkan penurunan yang lebih cepat dalam jumlah pasien yang masih berisiko dibandingkan kelompok EF $\geq$ 40%.

4. Gagal Jantung berdasarkan Kreatinin Serum

```

Hasil Uji Log-rank:
> print(log_rank_creat)
Call:
survdiff(formula = surv_object ~ creatinine_group_status, data = data)

              N Observed Expected
creatinine_group_status=Kreatinin Normal (≤1.2) 198      42      66.5
creatinine_group_status=Kreatinin Tinggi (>1.2) 101      54      29.5
              (O-E)^2/E (O-E)^2/V
creatinine_group_status=Kreatinin Normal (≤1.2)   9.0      29.4
creatinine_group_status=Kreatinin Tinggi (>1.2)  20.2      29.4

Chisq= 29.4 on 1 degrees of freedom, p= 6e-08

```


```

> cat("P-value:", round(p_creat, 4), "\n")
P-value: 0
> if(p_creat < 0.05) {
+   cat("Kesimpulan: Terdapat perbedaan signifikan berdasarkan kadar kreatinin
(p < 0.05)\n")
+ } else {
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan kadar krea
tinin (p >= 0.05)\n")
+ }
Kesimpulan: Terdapat perbedaan signifikan berdasarkan kadar kreatinin (p < 0.0
5)

```

Gambar 2.7 Hasil Uji Log-Rank Kreatinin Serum

Hasil uji log rank menunjukkan p-value yang sangat kecil <0.05 yang mengindikasikan terdapat perbedaan signifikan dalam kelangsungan hidup antara kelompok dengan kadar kreatinin normal dan tinggi.




Gambar 2.8 Hasil Kurva Kaplan-Meier Kreatinin Serum

Pada grafik ini, terlihat bahwa kelompok kreatinin normal (≤ 1.2) menunjukkan kelangsungan hidup yang lebih tinggi dan lebih stabil dibandingkan dengan kelompok kreatinin tinggi (> 1.2) yang mengindikasikan penurunan probabilitas kelangsungan hidup lebih cepat seiring berjalannya waktu. P-value nya juga sangat kecil yang mengindikasikan terdapat perbedaan signifikan dalam kelangsungan hidup antara kelompok dengan kadar kreatinin normal dan


tinggi. “Number at Risk” menunjukkan jumlah pasien yang berisiko berkurang seiring berjalannya waktu dengan kelompok kreatinin tinggi menunjukkan penurunan lebih cepat dalam jumlah pasien yang berisiko.

5. Gagal jantung berdasarkan Kadar Natrium Serum



Gambar 2.9 Hasil Uji Log-Rank Natrium Serum

Hasil uji log rank menunjukkan p-value yang sangat kecil <0.05 yang mengindikasikan terdapat perbedaan signifikan dalam kelangsungan hidup antara kelompok dengan kadar natrium rendah dan normal.



Gambar 2.10 Hasil Kurva Kaplan-Meier Natrium Serum

Dari grafik ini, terlihat bahwa kelompok kadar natrium rendah (<135) menunjukkan penurunan yang lebih cepat dalam probabilitas kelangsungan hidup dibandingkan dengan kelompok kadar natrium normal (≥ 135) yang memiliki kelangsungan hidup lebih baik dan lebih stabil sepanjang waktu. P-value nya juga sangat kecil yang mengindikasikan terdapat perbedaan signifikan dalam kelangsungan hidup antara kedua kelompok berdasarkan kadar natrium serum. “Number at Risk” menunjukkan jumlah pasien yang berisiko berkurang seiring berjalannya waktu dengan kelompok kadar natrium rendah menunjukkan penurunan yang lebih cepat dalam jumlah pasien yang berisiko.

6. Gagal jantung berdasarkan Anemia

```
Hasil Uji Log-rank:
> print(log_rank_anemia)
Call:
survdif(formula = surv_object ~ anemia_group_status, data = data)
```

	N	Observed	Expected	(O-E) ² /E
anemia_group_status=Tidak Anemia	170	50	57.9	1.07
anemia_group_status=Anemia	129	46	38.1	1.63


	(O-E) ² /V
anemia_group_status=Tidak Anemia	2.73
anemia_group_status=Anemia	2.73

Chisq= 2.7 on 1 degrees of freedom, p= 0.1

```
P-value: 0.0987
> if(p_anemia < 0.05) {
+   cat("Kesimpulan: Terdapat perbedaan signifikan berdasarkan anemia (p < 0.05)\n")
+ } else {
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan anemia (p >= 0.05)\n")
+ }
Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan anemia (p >= 0.05)
```

Gambar 2.11 Hasil Uji Log-Rank Anemia

Hasil uji log rank menunjukkan p-value > 0.05 yang mengindikasikan bahwa tidak terdapat perbedaan signifikan pada pasien yang memiliki anemia dan yang tidak memiliki anemia.



Gambar 2.12 Hasil Kurva Kaplan-Meier Anemia

Pada grafik ini, terlihat bahwa kelompok anemia menunjukkan sedikit penurunan dalam probabilitas kelangsungan hidup namun tidak terlalu berbeda signifikan dibandingkan dengan kelompok tidak anemia yang juga mengalami penurunan probabilitas kelangsungan hidup seiring berjalannya waktu. P-value nya juga lebih besar dari 0.05 yang mengindikasikan tidak ada perbedaan signifikan dalam kelangsungan hidup antara pasien dengan anemia dan tanpa anemia. “Number at Risk” menunjukkan jumlah pasien yang berisiko berkurang seiring berjalannya waktu dengan kelompok anemia menunjukkan penurunan yang sedikit lebih cepat dalam jumlah pasien yang masih berisiko dibandingkan kelompok tanpa anemia.

7. Gagal jantung berdasarkan Diabetes

```

Hasil Uji Log-rank:
> print(log_rank_diabetes)
Call:
survdiff(formula = surv_object ~ diabetes_group_status, data = data)

              N Observed Expected (O-E)^2/E
diabetes_group_status=Tidak Diabetes 174      56      55  0.0172
diabetes_group_status=Diabetes      125      40      41  0.0231
              (O-E)^2/V
diabetes_group_status=Tidak Diabetes  0.0405
diabetes_group_status=Diabetes      0.0405

Chisq= 0  on 1 degrees of freedom, p= 0.8

```


```

P-value: 0.8405
> if(p_diabetes < 0.05) {
+   cat("Kesimpulan: Terdapat perbedaan signifikan berdasarkan diabetes (p < 0.
05)\n")
+ } else {
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan diabetes
(p >= 0.05)\n")
+ }
Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan diabetes (p >= 0.0
5)

```

Gambar 2.13 Hasil Uji Log-Rank Diabetes

Hasil uji log rank menunjukkan p-value >0.05 yang mengindikasikan tidak terdapat perbedaan signifikan berdasarkan pasien yang memiliki diabetes dan yang tidak memiliki diabetes.



Gambar 2.14 Hasil Kurva Kaplan-Meier Diabetes

Pada grafik ini, terlihat bahwa kelompok tidak diabetes dan diabetes menunjukkan pola kelangsungan hidup yang sangat mirip. kedua kelompok memiliki penurunan probabilitas

kelangsungan hidup yang hampir serupa seiring berjalannya waktu. P-value nya juga >0.05 yang mengindikasikan tidak terdapat perbedaan yang signifikan. "Number at Risk" menunjukkan jumlah pasien yang berisiko berkurang seiring berjalannya waktu namun penurunan ini terjadi hampir secara seragam di kedua kelompok.

8. Gagal Jantung berdasarkan Hipertensi

```
Hasil Uji Log-rank:
> print(log_rank_hypertension)
Call:
survdiff(formula = surv_object ~ hypertension_group_status, data = data)


              N Observed Expected
hypertension_group_status=Tidak Hipertensi 194      57      66.4
hypertension_group_status=Hipertensi      105      39      29.6
              (O-E)^2/E (O-E)^2/V
hypertension_group_status=Tidak Hipertensi    1.34    4.41
hypertension_group_status=Hipertensi    3.00    4.41

Chisq= 4.4 on 1 degrees of freedom, p= 0.04
```

```
P-value: 0.0358
> if(p_hypertension < 0.05) {
+   cat("Kesimpulan: Terdapat perbedaan signifikan berdasarkan hipertensi (p <
0.05)\n")
+ } else {
+   cat("Kesimpulan: Tidak terdapat perbedaan signifikan berdasarkan hipertensi
(p >= 0.05)\n")
+ }
Kesimpulan: Terdapat perbedaan signifikan berdasarkan hipertensi (p < 0.05)
```

Gambar 2.15 Hasil Uji Log-Rank Hipertensi

Hasil uji log rank menunjukkan p-value <0.05 yang mengindikasikan terdapat perbedaan yang signifikan antara pasien yang memiliki hipertensi dengan yang tidak memiliki hipertensi.



Gambar 2.16 Hasil Kurva Kaplan-Meier Hipertensi

Dari grafik ini, terlihat bahwa kelompok tidak hipertensi menunjukkan kelangsungan hidup yang lebih tinggi dan lebih stabil sepanjang waktu dibandingkan dengan kelompok hipertensi yang menunjukkan penurunan probabilitas kelangsungan hidup lebih cepat. P-value nya juga <0.05 yang mengindikasikan terdapat perbedaan signifikan. "Number at Risk" menunjukkan jumlah pasien yang berisiko berkurang seiring berjalannya waktu dengan kelompok hipertensi menunjukkan penurunan yang lebih cepat dalam jumlah pasien yang masih berisiko.

3. Uji Asumsi Proportional Hazards (PH)

Uji asumsi proportional hazards (PH) merupakan langkah penting dalam analisis Cox regression untuk memastikan bahwa efek kovariat terhadap hazard function bersifat konstan seiring waktu. Dalam model Cox regression, asumsi PH menyatakan bahwa hazard ratio antara dua individu dengan nilai kovariat berbeda adalah konstan sepanjang waktu. Jika asumsi ini tidak terpenuhi, interpretasi hazard ratio (HR) bisa tidak valid karena risiko relatif berubah selama periode observasi. Dalam penelitian ini, uji asumsi PH dilakukan menggunakan uji statistik berbasis chi-square dan Schoenfeld residuals untuk mengevaluasi apakah variabel prediktor dalam model memenuhi syarat proporsionalitas.

Menggunakan bantuan Python, didapatkan hasil uji asumsi PH berbasis Chi-Square sebagai berikut:

```
=== Hasil Uji Asumsi Proportional Hazards ===
```

time_transform	rank
null_distribution	chi squared
degrees_of_freedom	1
model	<lifelines.CoxPHFitter: fitted with 299 total ...
test_name	proportional_hazard_test
	test_statistic p -log2(p)
age	0.03 0.86 0.21
anaemia	0.01 0.93 0.11
creatinine_phosphokinase	1.11 0.29 1.77
diabetes	0.00 0.99 0.02
ejection_fraction	6.21 0.01 6.30
high_blood_pressure	0.11 0.74 0.44
platelets	0.11 0.74 0.44
serum_creatinine	3.48 0.06 4.00
serum_sodium	1.73 0.19 2.41
sex	0.26 0.61 0.71
smoking	0.33 0.57 0.82


Gambar 3.1 Hasil Uji Asumsi PH Berbasis Chi-Square

Berdasarkan hasil uji asumsi PH yang dilakukan dengan pendekatan rank-transformed time dan distribusi chi-squared, sebagian besar variabel menunjukkan nilai p yang besar (> 0.05), mengindikasikan bahwa asumsi PH tidak dilanggar. Secara spesifik, variabel seperti age ($p = 0.86$), anaemia ($p = 0.93$), diabetes ($p = 0.99$), dan smoking ($p = 0.57$) memiliki nilai p yang tinggi, menunjukkan efek mereka terhadap risiko tidak berubah signifikan seiring waktu. Namun, variabel ejection_fraction menonjol dengan nilai $p = 0.01$ dan test statistic 6.21, yang signifikan pada tingkat 5%, menunjukkan **pelanggaran asumsi PH**, sehingga efeknya terhadap risiko mungkin bervariasi seiring waktu. Variabel serum_creatinine ($p = 0.06$) juga mendekati ambang batas signifikan, memerlukan perhatian lebih lanjut. Hasil ini menyarankan perlunya penyesuaian model, seperti stratifikasi atau penambahan interaksi waktu, khususnya untuk ejection_fraction, agar analisis lebih akurat.


Dalam uji Schoenfeld residuals akan dipergunakan dua bentuk transformasi, yaitu Rank-Transformed Time dan KM-Transformed Time. Rank-transformed time mengacu pada transformasi waktu kejadian (event times) menjadi peringkat (rank) berdasarkan urutan waktu kejadian tersebut. Pada uji Schoenfeld residuals, residuals ini diplot atau diuji korelasinya terhadap peringkat waktu kejadian. Jika terdapat korelasi signifikan antara residuals dan rank-transformed time, ini menunjukkan bahwa efek variabel prediktor terhadap hazard function berubah seiring waktu, sehingga melanggar asumsi PH.

Di sisi lain, KM-transformed time merujuk pada transformasi waktu berdasarkan estimasi Kaplan-Meier (KM) dari fungsi survival. Dalam pendekatan ini, waktu kejadian ditransformasikan menggunakan nilai kumulatif hazard atau fungsi survivor yang diestimasi dari kurva Kaplan-Meier. Transformasi ini memperhitungkan distribusi waktu kejadian yang disensor (censored) dalam data. Oleh karena itu, Schoenfeld residuals diuji terhadap waktu yang telah ditransformasikan menggunakan estimasi Kaplan-Meier. Pendekatan ini sering digunakan untuk menangani data dengan penyensoran (censoring) yang signifikan, karena transformasi KM memberikan bobot yang lebih tepat pada waktu kejadian dengan mempertimbangkan distribusi survival.


Adapun diperoleh hasil uji Schoenfeld residuals sebagai berikut:




Gambar 3.2 Plot Schoenfeld Residuals untuk Variabel Umur dan Anaemia




Gambar 3.3 Plot Schoenfeld Residuals untuk Variabel Creatinine Phosphokinase dan Diabetes




Gambar 3.4 Plot Schoenfeld Residuals untuk Variabel Ejection Fraction Dan Tekanan Darah



Gambar 3.5 Plot Schoenfeld Residuals untuk Variabel Platelets dan Serum Creatinine



Gambar 3.6 Plot Schoenfeld Residuals untuk Variabel Serum Sodium dan Jenis Kelamin



Gambar 3.7 Plot Schoenfeld Residuals untuk Variabel Merokok

Dalam menginterpretasikan plot Schoenfeld residuals, jika residuals (titik-titik pada plot) tersebar secara acak di sekitar garis nol (garis putus-putus horizontal) tanpa pola tren yang jelas, ini menunjukkan bahwa asumsi PH terpenuhi. Dengan kata lain, kurva smoothing (garis hitam) yang mendekati garis nol mendukung hal ini. Di sisi lain, jika residuals menunjukkan pola sistematis (misalnya, tren naik atau turun seiring waktu), ini mengindikasikan pelanggaran asumsi PH, karena efek kovariat berubah seiring waktu. Cara lain adalah dengan melihat nilai p yang ada pada plot. Jika $p > 0.05$, asumsi PH tidak dilanggar, menunjukkan efek kovariat konstan seiring waktu. Jika $p < 0.05$, asumsi PH dilanggar, menunjukkan adanya variasi efek kovariat seiring waktu.

Serupa dengan hasil uji sebelumnya, pada uji Schoenfeld residuals didapatkan bahwa sebagian besar variabel menunjukkan nilai p yang besar (> 0.05), kecuali untuk variabel `ejection_fraction`. Terlihat bahwa variabel `ejection_fraction` memiliki nilai $p = 0.0127$ untuk rank-transformed time dan nilai $p = 0.0156$ untuk km-transformed time. Kedua nilai p yang kecil (< 0.05) tersebut mendukung kesimpulan bahwa **variabel `ejection_fraction` melanggar asumsi proportional hazards**.

null_distribution		chi squared	
degrees_of_freedom		1	
model		<lifelines.CoxPHFitter: fitted with 299 total ...	
test_name		proportional_hazard_test	
		test_statistic	-log2(p)
age	km	0.11 0.74	0.43
	rank	0.03 0.86	0.21
anaemia	km	0.00 1.00	0.00
	rank	0.01 0.93	0.11
creatinine_phosphokinase	km	1.13 0.29	1.79
	rank	1.11 0.29	1.77
diabetes	km	0.04 0.84	0.25
	rank	0.00 0.99	0.02
ejection_fraction	km	5.85 0.02	6.00
	rank	6.21 0.01	6.30
high_blood_pressure	km	0.11 0.74	0.44
	rank	0.11 0.74	0.44
platelets	km	0.04 0.85	0.24
	rank	0.11 0.74	0.44
serum_creatinine	km	3.22 0.07	3.78
	rank	3.48 0.06	4.00
serum_sodium	km	1.10 0.29	1.76
	rank	1.73 0.19	2.41
sex	km	0.09 0.76	0.39
	rank	0.26 0.61	0.71
smoking	km	0.58 0.45	1.16
	rank	0.33 0.57	0.82

Gambar 3.8 Hasil Uji Asumsi PH Setelah Rank dan KM Transformation

4. Pemodelan Menggunakan Model Regresi Cox-PH

Setelah mengetahui bahwa seluruh variabel, kecuali variabel `ejection_fraction`, memenuhi asumsi Cox-PH, akan dilakukan pemodelan. Pertama, akan dilakukan pemodelan menggunakan seluruh variabel, dengan memperhitungkan tidak terpenuhinya asumsi PH pada `ejection_fraction`. Menggunakan semua variabel, diperoleh hasil sebagai berikut:

```
Call:
coxph(formula = Surv(time, DEATH_EVENT) ~ age + anaemia + creatinine_phosphokinase +
      diabetes + tt(ejection_fraction) + high_blood_pressure +
      platelets + serum_creatinine + serum_sodium + sex + smoking,
      data = heart, tt = function(x, t, ...) x * log(t))

n= 299, number of events= 96
```

	coef	exp(coef)	se(coef)	z	Pr(> z)	
age	4.663e-02	1.048e+00	9.349e-03	4.988	6.11e-07	***
anaemia	4.787e-01	1.614e+00	2.170e-01	2.206	0.0274	*
creatinine_phosphokinase	2.254e-04	1.000e+00	9.918e-05	2.272	0.0231	*
diabetes	1.269e-01	1.135e+00	2.226e-01	0.570	0.5687	
tt(ejection_fraction)	-1.356e-02	9.865e-01	2.775e-03	-4.887	1.02e-06	***
high_blood_pressure	4.916e-01	1.635e+00	2.162e-01	2.274	0.0230	*
platelets	-5.229e-07	1.000e+00	1.137e-06	-0.460	0.6457	
serum_creatinine	3.219e-01	1.380e+00	7.004e-02	4.597	4.29e-06	***
serum_sodium	-4.323e-02	9.577e-01	2.346e-02	-1.843	0.0653	.
sex	-2.416e-01	7.854e-01	2.512e-01	-0.962	0.3361	
smoking	1.166e-01	1.124e+00	2.514e-01	0.464	0.6427	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	exp(coef)	exp(-coef)	lower .95	upper .95
age	1.0477	0.9544	1.0287	1.0671
anaemia	1.6140	0.6196	1.0548	2.4695
creatinine_phosphokinase	1.0002	0.9998	1.0000	1.0004
diabetes	1.1353	0.8808	0.7339	1.7563
tt(ejection_fraction)	0.9865	1.0137	0.9812	0.9919
high_blood_pressure	1.6349	0.6117	1.0702	2.4975
platelets	1.0000	1.0000	1.0000	1.0000
serum_creatinine	1.3798	0.7247	1.2028	1.5828
serum_sodium	0.9577	1.0442	0.9147	1.0027
sex	0.7854	1.2733	0.4800	1.2849
smoking	1.1237	0.8899	0.6865	1.8394

Concordance= 0.741 (se = 0.027)
Likelihood ratio test= 84.9 on 11 df, p=2e-13
Wald test = 89.82 on 11 df, p=2e-14
Score (logrank) test = 90.85 on 11 df, p=1e-14

Gambar 4.1. Pemodelan regresi Cox-PH menggunakan semua variabel

Di model ini, digunakan fungsi `tt(ejection_fraction) = ejection_fraction * log(t)`, karena memang variabel `ejection_fraction` tidak memenuhi asumsi PH. Fungsi logaritma dari waktu dipilih karena umumnya transformasi yang digunakan memang menggunakan logaritma. Selain itu, pada model matematis, parameter-nya akan berada di atas eksponen, sehingga penggunaan logaritma untuk menghilangkan eksponen masuk akal.

Dari Gambar 4.1, dapat terlihat bahwa tidak semua variabel signifikan dalam model regresi ini. Meskipun concordance-nya cukup baik, yaitu 0.741, model ini masih belum parsimoni karena terdapat banyak variabel yang tidak relevan/signifikan. Oleh karena itu, akan dilakukan stepwise selection untuk menentukan variabel yang akan digunakan dalam model. Stepwise selection dilakukan dengan

melihat p-value dan bukan dengan menggunakan AIC. Proses stepwise yang dilakukan sebagai berikut:

- Pertama dimasukkan variabel serum_creatinine dengan p-value = 1.185545×10^{-7}
- Kemudian dimasukkan variabel tt(ejection_fraction) dengan p-value = 9.299068×10^{-7}
- Kemudian dimasukkan variabel age dengan p-value = 7.932999×10^{-7}
- Kemudian dimasukkan variabel high_blood_pressure dengan p-value = 0.02099413
- Kemudian sudah tidak ada variabel yang signifikan, sehingga stepwise selection selesai

Menggunakan stepwise selection, diperoleh hanya 4 variabel yang signifikan, yaitu variabel serum_creatinine, tt(ejection_fraction), age, dan high_blood_pressure. Jika keempat variabel tersebut kemudian dimodelkan kembali menggunakan Cox-PH, diperoleh hasil sebagai berikut.

```
Call:
coxph(formula = f, data = data, tt = list(tt_var = tt_func))

n= 299, number of events= 96
```

	coef	exp(coef)	se(coef)	z	Pr(> z)	
serum_creatinine	0.346367	1.413922	0.067049	5.166	2.39e-07	***
tt(ejection_fraction)	-0.013594	0.986498	0.002634	-5.161	2.45e-07	***
age	0.044419	1.045420	0.009059	4.903	9.43e-07	***
high_blood_pressure	0.488009	1.629069	0.211434	2.308	0.021	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	exp(coef)	exp(-coef)	lower .95	upper .95
serum_creatinine	1.4139	0.7073	1.2398	1.6125
tt(ejection_fraction)	0.9865	1.0137	0.9814	0.9916
age	1.0454	0.9566	1.0270	1.0641
high_blood_pressure	1.6291	0.6138	1.0764	2.4655

Concordance= 0.726 (se = 0.03)
Likelihood ratio test= 74.05 on 4 df, p=3e-15
Wald test = 81.56 on 4 df, p=<2e-16
Score (logrank) test = 80.43 on 4 df, p=<2e-16

Gambar 4.2. Pemodelan regresi menggunakan variabel yang signifikan menurut stepwise selection

Seperti yang dapat dilihat, seluruh variabel sekarang signifikan dengan p-value yang lebih kecil daripada 0.05. Lebih lanjut, concordance-nya juga tidak berbeda terlalu jauh dari concordance sebelumnya, yaitu 0.726. Kemudian, dapat dilihat juga hasil uji hipotesis yang masih memberikan hasil yang signifikan, dengan p-value sangat kecil. Artinya, model yang diperoleh sudah cukup baik secara statistik dan parsimoni.

Selanjutnya, model matematis dari output R ini dapat ditulis sebagai berikut:

$$h(t) = h_0(t) \exp(\beta_1 X_1 + \beta_2 X_2 \ln t + \beta_3 X_3 + \beta_4 X_4)$$

dengan keterangan sebagai berikut:

- $h(t)$ adalah fungsi hazard di waktu t
- $h_0(t)$ adalah fungsi hazard baseline di waktu t (atau sama dengan fungsi hazard saat semua variabel X_1, X_2, X_3, X_4 adalah nol)
- X_1 adalah nilai dari serum_creatinine
- β_1 adalah estimasi koefisien dari X_1
- X_2 adalah nilai dari ejection_fraction

- β_2 adalah estimasi koefisien dari X_2
- X_3 adalah nilai dari age
- β_3 adalah estimasi koefisien dari X_3
- X_4 adalah nilai dari high_blood_pressure
- β_4 adalah estimasi koefisien dari X_4

Jika menggunakan estimasi yang diperoleh dari R, model matematisnya menjadi

$$h(t) = h_0(t) \exp(0.346367X_1 - 0.013594X_2 \ln t + 0.044419X_3 + 0.488009X_4)$$

atau, karena model Cox-PH ini tidak sepenuhnya memenuhi PH, menjadi

$$h(t) = h_0(t) \cdot t^{-0.013594X_2} \cdot \exp(0.346367X_1 + 0.044419X_3 + 0.488009X_4).$$

Model yang tertulis di atas adalah model yang diperoleh jika estimasi parameter dilakukan dengan menggunakan metode Efron. Hasil yang berbeda bisa saja terjadi jika digunakan metode lainnya, seperti metode Breslow atau metode Diskrit. Menggunakan metode Breslow, diperoleh hasil estimasi parameter sebagai berikut:

```
Call:
coxph(formula = f, data = data, ties = method, tt = list(tt_var = tt_func))

n= 299, number of events= 96

              coef exp(coef) se(coef)      z Pr(>|z|)
serum_creatinine  0.336539  1.400094  0.066526  5.059 4.22e-07 ***
tt(ejection_fraction) -0.013569  0.986523  0.002645 -5.130 2.90e-07 ***
age               0.044162  1.045152  0.009067  4.871 1.11e-06 ***
high_blood_pressure  0.482295  1.619788  0.211582  2.279  0.0226 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

              exp(coef) exp(-coef) lower .95 upper .95
serum_creatinine      1.4001      0.7142      1.2289      1.5951
tt(ejection_fraction)  0.9865      1.0137      0.9814      0.9917
age                   1.0452      0.9568      1.0267      1.0639
high_blood_pressure    1.6198      0.6174      1.0699      2.4522

Concordance= 0.726 (se = 0.03 )
Likelihood ratio test= 73.26 on 4 df,  p=5e-15
Wald test               = 80.9 on 4 df,  p=<2e-16
Score (logrank) test = 79.76 on 4 df,  p=<2e-16
```

Gambar 4.3. Pemodelan regresi menggunakan variabel stepwise selection dan metode Breslow

Maka model Cox-PH nya menjadi

$$h(t) = h_0(t) \cdot t^{-0.013569X_2} \cdot \exp(0.336539X_1 + 0.044162X_3 + 0.482295X_4).$$

Kemudian, menggunakan metode Diskrit, diperoleh hasil estimasi sebagai berikut:

```

call:
coxph(formula = f, data = data, ties = method, tt = list(tt_var = tt_func))

n= 299, number of events= 96

              coef exp(coef) se(coef)      z Pr(>|z|)
serum_creatinine  0.350157  1.419290  0.069481  5.040 4.66e-07 ***
tt(ejection_fraction) -0.013681  0.986412  0.002643 -5.177 2.26e-07 ***
age               0.044726  1.045741  0.009113  4.908 9.20e-07 ***
high_blood_pressure  0.493103  1.637390  0.212425  2.321  0.0203 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

              exp(coef) exp(-coef) lower .95 upper .95
serum_creatinine      1.4193      0.7046      1.2386      1.6263
tt(ejection_fraction)  0.9864      1.0138      0.9813      0.9915
age                   1.0457      0.9563      1.0272      1.0646
high_blood_pressure    1.6374      0.6107      1.0798      2.4830

Concordance= 0.726 (se = 0.03 )
Likelihood ratio test= 74.02 on 4 df,  p=3e-15
Wald test               = 78.31 on 4 df,  p=4e-16
Score (logrank) test = 80.04 on 4 df,  p=<2e-16

```

Gambar 4.4. Pemodelan regresi menggunakan variabel stepwise selection dan metode Diskrit

Maka model Cox-PH nya menjadi

$$h(t) = h_0(t) \cdot t^{-0.013681X_2} \cdot \exp(0.350157X_1 + 0.044726X_3 + 0.493103X_4).$$

Perhatikan bahwa untuk ketiga metode estimasi parameter, hasil estimasi tidak terlalu berbeda jauh. Concordance masing-masing metode juga tidak berbeda, masih bernilai 0.726. Perbedaan estimasi setiap koefisien dapat dirangkum ke dalam tabel berikut:

	Metode Efron	Metode Breslow	Metode Diskrit
Estimasi parameter serum_creatinine	0.346367	0.336539	0.350157
Estimasi parameter tt(ejection_fraction)	-0.013594	-0.013569	-0.013681
Estimasi parameter age	0.044419	0.044162	0.044726
Estimasi parameter high_blood_pressure	0.488009	0.482295	0.493103

Untuk mempercepat interpretasi, hanya akan diinterpretasikan model yang diperoleh menggunakan metode Efron. Hal ini karena interpretasi untuk metode-metode lainnya dapat dilakukan dengan cara dan bahasa yang hampir sama, dimana perbedaannya hanya pada angka estimasinya.

Untuk variabel serum_creatinine, perhatikan bahwa di tabel kedua pada Gambar 4.2, nilai exp(coef) adalah 1.4139 dengan interval kepercayaan 95% yaitu (1.2398, 1.6125), dan nilai exp(-coef) adalah 0.7073. Karena serum_creatinine adalah variabel numerik, hal ini bisa diinterpretasikan sebagai

berikut: Untuk setiap kenaikan 1 satuan pada serum_creatinine, terjadi peningkatan resiko kematian sebesar 41.39%, dengan kepercayaan 95% bahwa peningkatan ini berada di antara 23.98% sampai 61.25%.

Untuk variabel ejection_fraction, yang tidak memenuhi asumsi hazard proporsional, perhatikan bahwa di tabel kedua pada Gambar 4.2, nilai $\exp(\text{coef})$ adalah 0.9865 dengan interval kepercayaan 95% yaitu (0.9814, 0.9916), dan nilai $\exp(-\text{coef})$ adalah 1.0137. Karena ejection_fraction adalah variabel numerik, hal ini bisa diinterpretasikan sebagai berikut: Untuk setiap kenaikan 1 satuan pada ejection_fraction di suatu waktu t tertentu, resiko kematian akan menurun dengan kelipatan sebesar $t^{-0.013594}$ atau sebesar $(98.65\%)^{\ln(t)}$ dari nilai ejection_fraction awal, dengan kepercayaan 95% bahwa kelipatan ini berada di antara $(98.14\%)^{\ln(t)}$ sampai $(99.16\%)^{\ln(t)}$. Hal ini berarti resiko kematian akan lebih kecil untuk nilai t yang besar dan nilai ejection_fraction yang besar juga.

Untuk variabel age, perhatikan bahwa di tabel kedua pada Gambar 4.2, nilai $\exp(\text{coef})$ adalah 1.0454 dengan interval kepercayaan 95% yaitu (1.0270, 1.0641), dan nilai $\exp(-\text{coef})$ adalah 0.9566. Karena age adalah variabel numerik, hal ini bisa diinterpretasikan sebagai berikut: Untuk setiap kenaikan 1 satuan pada age/usia, terjadi peningkatan resiko kematian sebesar 4.54%, dengan kepercayaan 95% bahwa peningkatan ini berada di antara 2.70% sampai 6.41%.

Untuk variabel high_blood_pressure, perhatikan bahwa di tabel kedua pada Gambar 4.2, nilai $\exp(\text{coef})$ adalah 1.6291 dengan interval kepercayaan 95% yaitu (1.0764, 2.4655), dan nilai $\exp(-\text{coef})$ adalah 0.6138. Karena high_blood_pressure adalah variabel numerik dimana 1 berarti pasien memiliki tekanan darah tinggi dan 0 berarti pasien tidak memiliki tekanan darah tinggi, hal ini bisa diinterpretasikan sebagai berikut: Pasien yang memiliki tekanan darah tinggi memiliki resiko kematian sebesar 62.91% lebih tinggi dibandingkan dengan pasien yang tidak memiliki tekanan darah tinggi, dengan kepercayaan 95% bahwa resiko kematian pasien dengan tekanan darah tinggi 7.64% sampai 146.55% lebih tinggi daripada pasien yang tidak memiliki tekanan darah tinggi.

5. Pengujian Hipotesis

Pengujian hipotesis dilakukan untuk menyelami lebih dalam beberapa aspek spesifik yang terkandung dalam data, dengan tujuan untuk mendapatkan wawasan yang lebih mendalam dan akurat mengenai pola atau hubungan yang mungkin ada. Dalam proses analisis ini, kami merencanakan pelaksanaan tiga jenis pengujian yang berbeda untuk memastikan evaluasi yang komprehensif terhadap data yang dimiliki.

1. Uji 2 sampel atau lebih

Pada uji ini, kami memilih untuk menggunakan metode Log-Rank, sebuah pendekatan statistik yang sangat efektif, untuk menganalisis beberapa variabel kunci yang dianggap relevan.

Hipotesis:

$$H_0: h_1(t) = h_2(t) = \dots = h_k(t) \text{ untuk semua } t \leq \tau$$

H_1 : tidak demikian

- Variabel Anemia

--- Hasil Uji untuk: ANAEMIA ---			
t_0	-1		
null_distribution	chi squared		
degrees_of_freedom	1		
test_name	logrank_test		
test_statistic	p	-log2(p)	
0	2.73	0.10	3.34

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,10. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak** H_0 . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang menderita anemia atau tidak.

- Variabel Diabetes

--- Hasil Uji untuk: DIABETES ---			
t_0	-1		
null_distribution	chi squared		
degrees_of_freedom	1		
test_name	logrank_test		
test_statistic	p	-log2(p)	
0	0.04	0.84	0.25

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,84. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak** H_0 . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang menderita diabetes atau tidak.

- Variabel High Blood Pressure (Hipertensi)

```
--- Hasil Uji untuk: HIGH_BLOOD_PRESSURE ---
```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	1
test_name	logrank_test
test_statistic	p -log2(p)
0	4.41 0.04 4.80

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,04. Nilai p-value yang lebih kecil dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **menolak** H_0 . Sehingga dapat disimpulkan bahwa **ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang menderita hipertensi atau tidak.

- Variabel Sex (Jenis Kelamin)

```
--- Hasil Uji untuk: SEX ---
```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	1
test_name	logrank_test
test_statistic	p -log2(p)
0	0.00 0.95 0.07

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,95. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak** H_0 . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang berjenis kelamin laki-laki atau perempuan.

- Variabel Smoking

```
--- Hasil Uji untuk: SMOKING ---
```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	1
test_name	logrank_test
test_statistic	p -log2(p)
0	0.00 0.96 0.05

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,96. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak** H_0 . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang menderita diabetes atau tidak.

2. Uji Trend

Pada Uji Trend akan dilakukan kepada beberapa variabel untuk melihat apakah terdapat pola atau kecenderungan yang konsisten seiring dengan perubahan waktu atau kategori tertentu dalam data yang diamati. Pengujian ini bertujuan untuk mengidentifikasi hubungan monotonik antara variabel-variabel tersebut dan waktu kejadian, sehingga dapat memberikan gambaran yang lebih jelas tentang dinamika yang terjadi di antara kelompok-kelompok yang dibandingkan.

Hipotesis:

$$H_0: h_1(t) = h_2(t) = \dots = h_k(t) \text{ untuk } t \leq \tau$$

$$H_1: h_1(t) \leq h_2(t) \leq \dots \leq h_k(t) \text{ untuk } t \leq \tau, \text{ dengan paling tidak satu ketidaksamaan}$$

- Variabel Age


```

--- Hasil Uji Trend untuk: AGE ---

```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	2
test_name	multivariate_logrank_test
test_statistic	p -log2(p)
0	30.55 <0.005 22.04

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value <0,005. Nilai p-value yang lebih kecil dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **menolak** H_0 . Sehingga dapat disimpulkan bahwa **ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien dari grup umur yang berbeda. Berikut kurva survival untuk variabel Age pasien dari masing masing grup.



- Variabel Ejection Fraction

```


--- Hasil Uji Trend untuk: EJECTION_FRACTION ---

```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	2
test_name	multivariate_logrank_test
test_statistic	p -log2(p)
0	31.05 <0.005 22.40

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value <0,005. Nilai p-value yang lebih kecil dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **menolak** H_0 . Sehingga dapat


disimpulkan bahwa **ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien dari grup Ejection Fraction yang berbeda. Berikut kurva survival untuk variabel Ejection Fraction pasien dari masing masing grup.



- Variabel Serum Creatinine

--- Hasil Uji Trend untuk: SERUM_CREATININE ---			
t_0	-1		
null_distribution	chi squared		
degrees_of_freedom	2		
test_name	multivariate_logrank_test		
test_statistic	p	-log2(p)	
0	53.05	<0.005	38.26


Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value <0,005. Nilai p-value yang lebih kecil dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **menolak** H_0 . Sehingga dapat disimpulkan bahwa **ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien dari grup Serum Creatinine yang berbeda. Berikut kurva survival untuk variabel Serum Creatinine pasien dari masing masing grup.



- Variabel Platelets

--- Hasil Uji Trend untuk: PLATELETS ---			
t_0	-1		
null_distribution	chi squared		
degrees_of_freedom	2		
test_name	multivariate_logrank_test		
test_statistic	p	-log2(p)	
0	0.67	0.72	0.48


Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,72. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak H_0** . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien dari grup Platelets yang berbeda. Berikut kurva survival untuk variabel Platelets pasien dari masing masing grup.



- Variabel Creatinine Phosphokinase

--- Hasil Uji Trend untuk: CREATININE_PHOSPHOKINASE ---			
t_0	-1		
null_distribution	chi squared		
degrees_of_freedom	2		
test_name	multivariate_logrank_test		
test_statistic	p	-log2(p)	
0	0.87	0.65	0.63

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p-value sebesar 0,65. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak H_0** . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien dari grup Creatinine Phosphokinase yang berbeda. Berikut kurva survival untuk variabel Creatinine Phosphokinase pasien dari masing masing grup.



- Variabel Serum Sodium


```

--- Hasil Uji Trend untuk: SERUM_SODIUM ---

```

t_0	-1
null_distribution	chi squared
degrees_of_freedom	2
test_name	multivariate_logrank_test
test_statistic	p -log2(p)
0	16.28 <0.005 11.74

Berdasarkan uji yang telah dilakukan, kita dapatkan nilai p -value $<0,005$. Nilai p -value yang lebih kecil dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **menolak** H_0 . Sehingga dapat disimpulkan bahwa **ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien dari grup Serum Sodium yang berbeda. Berikut kurva survival untuk variabel Serum Sodium pasien dari masing masing grup.



3. Uji Stratified

Pada Uji Stratified ini, kami menggunakan model Cox Proportional Hazards (Cox PH) sebagai pendekatan utama untuk menguji pengaruh suatu variabel tertentu terhadap waktu kejadian, dengan memanfaatkan strata berupa variabel lain sebagai pengontrol untuk memastikan analisis yang lebih akurat dan terperinci. Metode ini dilakukan untuk memisahkan efek dari variabel utama yang sedang

diuji dari potensi pengaruh pengganggu yang mungkin timbul akibat perbedaan pada variabel strata, sehingga hasil yang diperoleh dapat mencerminkan hubungan yang lebih murni dan spesifik.

Hipotesis:

$H_0: h_{1s}(t) = h_{2s}(t) = \dots = h_{Ks}(t)$ untuk $s = 1, \dots, M, t \leq \tau$

H_1 : tidak demikian

- Efek Variabel Smoking dengan strata Variabel Age

--- Uji A: Efek SMOKING, dikontrol oleh AGE ---	
model	lifelines.CoxPHFitter
duration col	'time'
event col	'DEATH_EVENT'
strata	age_strata
baseline estimation	breslow
number of observations	299
number of events observed	96
partial log-likelihood	-402.59
time fit was run	2025-06-08 15:57:41 UTC

	coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
smoking	0.03	1.03	0.22	-0.40	0.46	0.67	1.59	0.00	0.14	0.89	0.17

Concordance	0.51
Partial AIC	807.18
log-likelihood ratio test	0.02 on 1 df
-log2(p) of ll-ratio test	0.17

Berdasarkan uji yang stratified dilakukan, kita dapatkan nilai p-value sebesar 0,89. Nilai p-value yang lebih besar dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **gagal menolak H_0** . Sehingga dapat disimpulkan bahwa **tidak ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang merokok atau tidak merokok setelah mempertimbangkan variabel usia.

- Efek Variabel High Blood Pressure dengan strata Variabel Sex

--- Uji B: Efek HIGH_BLOOD_PRESSURE, dikontrol oleh SEX ---	
model	lifelines.CoxPHFitter
duration col	'time'
event col	'DEATH_EVENT'
strata	sex
baseline estimation	breslow
number of observations	299
number of events observed	96
partial log-likelihood	-444.79
time fit was run	2025-06-08 15:57:41 UTC

	coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
high_blood_pressure	0.43	1.54	0.21	0.02	0.85	1.02	2.33	0.00	2.07	0.04	4.69

Concordance	0.56
Partial AIC	891.58
log-likelihood ratio test	4.14 on 1 df
$-\log_2(p)$ of ll-ratio test	4.58

Berdasarkan uji yang stratified dilakukan, kita dapatkan nilai p-value sebesar 0,04. Nilai p-value yang lebih kecil dari batas signifikansi ($\alpha = 0.05$) mengindikasikan kita **menolak** H_0 . Sehingga dapat disimpulkan bahwa **ditemukan** adanya bukti statistik yang cukup kuat untuk menyatakan terdapat perbedaan kelangsungan hidup yang signifikan secara statistik di antara pasien yang memiliki hipertensi atau tidak setelah mempertimbangkan variabel Sex (jenis kelamin).

6. Kesimpulan

Berdasarkan analisis yang telah dilakukan, eksplorasi dan visualisasi yang dilakukan di awal memberi petunjuk mengenai variabel-variabel yang signifikan dalam memodelkan resiko kematian. Kemudian, matriks korelasi juga tidak menunjukkan adanya variabel independen yang memiliki korelasi yang tinggi satu dengan yang lain, sehingga bisa dikatakan tidak terdapat multikolinearitas pada data.

Kemudian, estimasi nonparametrik menggunakan estimasi Kaplan-Meier juga menunjukkan beberapa hal, contohnya seperti adanya perbedaan resiko kematian untuk usia yang berbeda, dimana usia yang dibawah 65 tahun cenderung memiliki resiko kematian yang lebih rendah dibandingkan usia yang lebih dari 65 tahun. Kemudian, dilakukan juga estimasi menggunakan variabel-variabel lainnya, diantaranya yang signifikan berbeda yaitu fraksi ejeksi, serum kreatinin, serum sodium/natrium, dan hipertensi. Meskipun demikian, variabel-variabel yang signifikan ini tentu perlu dianalisis lebih lanjut sebelum dimodelkan menggunakan model regresi Cox-PH.

Salah satu analisis yang perlu dilakukan sebelum dilakukan pemodelan, terutama model Cox-PH, adalah memeriksa apakah memang asumsi PH (proportional hazard) terpenuhi, karena jika tidak maka tidak dapat dilakukan pemodelan Cox-PH. Menggunakan uji asumsi PH, diperoleh hasil bahwa seluruh variabel memenuhi asumsi tersebut kecuali variabel fraksi ejeksi.

Dengan mengetahui informasi tersebut, dapat disimpulkan bahwa fraksi ejeksi tidak dapat dimodelkan tanpa adanya pengaruh terhadap waktu. Oleh karena itu, variabel tersebut dikalikan dengan logaritma dari waktu sehingga diperoleh model akhir yang dipilih menggunakan stepwise selection yaitu

$$h(t) = h_0(t) \cdot t^{-0.013594X_2} \cdot \exp(0.346367X_1 + 0.044419X_3 + 0.488009X_4),$$

dimana X_1 adalah variabel serum kreatinin, X_2 adalah variabel fraksi ejeksi, X_3 adalah variabel usia pasien, dan X_4 adalah variabel tekanan darah pasien (1 jika tinggi, 0 jika rendah). Model ini bukan sepenuhnya model PH karena terdapat perkalian dengan pangkat dari waktu yang berhubungan dengan variabel fraksi ejeksi. Meskipun demikian, model tetap harus dimodelkan seperti berikut karena memang variabel fraksi ejeksi signifikan terhadap event kematian.

Setelah didapat model akhir, dilakukan beberapa uji hipotesis, termasuk uji log-rank, uji tren, dan juga uji stratifikasi, pada seluruh variabel pada data. Hasil pengujian hipotesis ini mengkonfirmasi model yang telah diajukan, dimana model-model yang kurang signifikan memang tidak terdapat dalam model tetapi variabel-variabel yang signifikan terdapat pada model.

Sebagai saran, perhatikan bahwa variabel serum sodium/natrium signifikan baik dalam estimasi nonparametrik maupun dalam pengujian hipotesis, tetapi tidak signifikan dalam stepwise selection. Meskipun demikian, hal ini bisa saja terjadi karena stepwise selection yang dilakukan berdasarkan p-value dan bukan berdasarkan ukuran kriteria informasi seperti AIC atau BIC. Oleh karena itu, untuk saran percobaan selanjutnya, mungkin dapat dicoba untuk melakukan seleksi stepwise berdasarkan AIC dibandingkan p-value.

Lampiran

Drive Code :  PROJECT 3 MODSUR_KELOMPOK 6